2 Regresión lineal simple

MA2003B Aplicación de métodos multivariados
en ciencia de datos

Raul Gomez

Tecnológico de Monterrey

El modelo de regresión lineal simple

En un **modelo de regresión simple**, suponemos que tenemos una **variable independiente** X_0 (también conocida como **variable explicativa** o **predictora**), y una **variable dependiente** Y_0 (también conocida como **variable de respuesta**).

El modelo de regresión lineal simple

En un **modelo de regresión simple**, suponemos que tenemos una **variable independiente** X_0 (también conocida como **variable explicativa** o **predictora**), y una **variable dependiente** Y_0 (también conocida como **variable de respuesta**).

Suponemos además que estas variables satisfacen una relación de la forma:

$$Y_0 = f_0(X_0) + \varepsilon_0$$

donde f_0 es una función desconocida que describe la relación entre ambas variables, y ε_0 es una variable aleatoria que representa el **error** o **ruido** en la relación entre X_0 e Y_0.

El modelo de regresión lineal simple

En un **modelo de regresión simple**, suponemos que tenemos una **variable independiente** X_0 (también conocida como **variable explicativa** o **predictora**), y una **variable dependiente** Y_0 (también conocida como **variable de respuesta**).

Suponemos además que estas variables satisfacen una relación de la forma:

$$Y_0 = f_0(X_0) + \varepsilon_0$$

donde f_0 es una función desconocida que describe la relación entre ambas variables, y ε_0 es una variable aleatoria que representa el **error** o **ruido** en la relación entre X_0 e Y_0.

Uno de los objetivos del **aprendizaje estadístico** (también conocido como **aprendizaje automático** o **machine learning**), es tratar de aproximar la función f_0 a partir de un conjunto de datos

$$((x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n))$$

dado.

De manera más precisa, consideremos vectores aleatorios

$$X = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{bmatrix}, \quad Y = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}$$

que representan los posibles valores de las observaciones independientes y dependientes, respectivamente, en una muestra dada.

De manera más precisa, consideremos vectores aleatorios

$$X = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{bmatrix}, \quad Y = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}$$

que representan los posibles valores de las observaciones independientes y dependientes, respectivamente, en una muestra dada.

En este contexto, un **método de aprendizaje** consiste de una función $\hat{F}$, que depende de los vectores aleatorios X e Y, y que cuando se evalúa en los datos observados produce una función $\hat{f}$ que aproxima a la función desconocida f_0.

De manera más precisa, consideremos vectores aleatorios

$$X = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{bmatrix}, \quad Y = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}$$

que representan los posibles valores de las observaciones independientes y dependientes, respectivamente, en una muestra dada.

En este contexto, un **método de aprendizaje** consiste de una función $\hat{F}$, que depende de los vectores aleatorios X e Y, y que cuando se evalúa en los datos observados produce una función $\hat{f}$ que aproxima a la función desconocida f_0.

Observación

En muchos modelos de aprendizaje estadístico es común tomar el vector $X = x$ como fijo, en cuyo caso la función $\hat{F}$ depende únicamente del vector aleatorio Y.

Para hacer estas ideas un poco más concretas, consideremos el caso particular en el que la función desconocida f_0 es una función lineal, es decir,

$$f_0(X_0) = b_0 + b_1 X_0$$

y supondremos además que $\varepsilon_0 \sim \mathcal{N}(0, \sigma^2)$ es una variable aleatoria con distribución normal de media 0 y varianza σ^2.

Para hacer estas ideas un poco más concretas, consideremos el caso particular en el que la función desconocida f_0 es una función lineal, es decir,

$$f_0(X_0) = b_0 + b_1 X_0$$

y supondremos además que $\varepsilon_0 \sim \mathcal{N}(0, \sigma^2)$ es una variable aleatoria con distribución normal de media 0 y varianza σ^2.

Este contexto se conoce como el **modelo de regresión lineal simple** y es uno de los modelos más utilizados en aprendizaje estadístico.

Para hacer estas ideas un poco más concretas, consideremos el caso particular en el que la función desconocida f_0 es una función lineal, es decir,

$$f_0(X_0) = b_0 + b_1 X_0$$

y supondremos además que $\varepsilon_0 \sim \mathcal{N}(0, \sigma^2)$ es una variable aleatoria con distribución normal de media 0 y varianza σ^2.

Este contexto se conoce como el **modelo de regresión lineal simple** y es uno de los modelos más utilizados en aprendizaje estadístico.

Notemos que en este caso nuestro objetivo es encontrar una expresión que nos permita aproximar los parámetros desconocidos b_0 y b_1 en términos de los datos observados.

Para ello definiremos

$$\Phi = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}$$

y consideraremos las matrices

$$D^2 = (\Phi^T \Phi)^{-1}$$

Para ello definiremos

$$\Phi = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}$$

y consideraremos las matrices

$$D^2 = (\Phi^T \Phi)^{-1}$$

$$A = D^2 \Phi^T$$

Para ello definiremos

$$\Phi = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}$$

y consideraremos las matrices

$$D^2 = (\Phi^T \Phi)^{-1}$$

$$A = D^2 \Phi^T$$

$$H = \Phi A$$

Entonces podemos definir el **vector aleatorio de estimadores de mínimos cuadrados** como:

$$\hat{B} = AY$$

Entonces podemos definir el **vector aleatorio de estimadores de mínimos cuadrados** como:

$$\hat{B} = AY$$

Además, de las propiedades de la distribución normal multivariada, sabemos que

$$\hat{B} \sim \mathcal{N}(b, \sigma^2 D^2)$$

donde

$$b = \begin{bmatrix} b_0 \\ b_1 \end{bmatrix}$$

es el vector de parámetros desconocidos.

Notemos que, en particular, el vector aleatorio $\hat{B}$ es un estimador insesgado del vector de parámetros b, es decir,

$$E[\hat{B}] = b$$

Notemos que, en particular, el vector aleatorio $\hat{B}$ es un estimador insesgado del vector de parámetros b, es decir,

$$E[\hat{B}] = b$$

Notemos además que si evaluamos el vector aleatorio $\hat{B}$ en los datos observados $Y = y$, obtenemos el vector de coeficientes $\hat{\beta}$ de la recta de mejor ajuste por mínimos cuadrados.

Notemos que, en particular, el vector aleatorio $\hat{B}$ es un estimador insesgado del vector de parámetros b, es decir,

$$E[\hat{B}] = b$$

Notemos además que si evaluamos el vector aleatorio $\hat{B}$ en los datos observados $Y = y$, obtenemos el vector de coeficientes $\hat{\beta}$ de la recta de mejor ajuste por mínimos cuadrados.

Una vez hechas estas observaciones, nuestro siguiente objetivo será construir los intervalos de confianza para los parámetros b_0 y b_1.

Empecemos por definir las cantidades

$$d_0^2 = D_{11}^2 = \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}$$
$$d_1^2 = D_{22}^2 = \frac{1}{S_{xx}}$$

donde

$$S_{xx} = \sum_{i=1}^{n} (x_i - \bar{x})^2$$

Empecemos por definir las cantidades

$$d_0^2 = D_{11}^2 = \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}$$
$$d_1^2 = D_{22}^2 = \frac{1}{S_{xx}}$$

donde

$$S_{xx} = \sum_{i=1}^{n} (x_i - \bar{x})^2$$

Entonces

$$\hat{B}_0 \sim \mathcal{N}\left(b_0, \sigma^2 d_0^2\right)$$
$$\hat{B}_1 \sim \mathcal{N}\left(b_1, \sigma^2 d_1^2\right)$$

Consideremos ahora la variable aleatoria

$$\hat{S}^2 = \frac{1}{n-2}\sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2$$

donde

$$\hat{Y} = \begin{bmatrix} \hat{Y}_1 \\ \hat{Y}_2 \\ \vdots \\ \hat{Y}_n \end{bmatrix} = HY$$

es el **vector aleatorio de predicciones por mínimos cuadrados**.

Consideremos ahora la variable aleatoria

$$\hat{S}^2 = \frac{1}{n-2}\sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2$$

donde

$$\hat{Y} = \begin{bmatrix} \hat{Y}_1 \\ \hat{Y}_2 \\ \vdots \\ \hat{Y}_n \end{bmatrix} = HY$$

es el **vector aleatorio de predicciones por mínimos cuadrados**.

Entonces tenemos que

$$\frac{(n-2)\hat{S}^2}{\sigma^2} \sim \chi^2_{n-2}$$

y, además, la variable aleatoria $\hat{S}^2$ es independiente de las variables aleatorias $\hat{B}_0$ y $\hat{B}_1$.

Por lo tanto, podemos construir las nuevas variables aleatorias

$$T_0 = \frac{\hat{B}_0 - b_0}{\hat{S}d_0} \sim t_{n-2}$$
$$T_1 = \frac{\hat{B}_1 - b_1}{\hat{S}d_1} \sim t_{n-2}$$

donde t_{n-2} denota la distribución t de Student con $n-2$ grados de libertad.

Por lo tanto, podemos construir las nuevas variables aleatorias

$$T_0 = \frac{\hat{B}_0 - b_0}{\hat{S}d_0} \sim t_{n-2}$$
$$T_1 = \frac{\hat{B}_1 - b_1}{\hat{S}d_1} \sim t_{n-2}$$

donde t_{n-2} denota la distribución t de Student con $n-2$ grados de libertad.

Con esta información, podemos construir ahora los intervalos de confianza para los parámetros b_0 y b_1, tal y como nos lo habíamos propuesto.

Por lo tanto, podemos construir las nuevas variables aleatorias

$$T_0 = \frac{\hat{B}_0 - b_0}{\hat{S}d_0} \sim t_{n-2}$$
$$T_1 = \frac{\hat{B}_1 - b_1}{\hat{S}d_1} \sim t_{n-2}$$

donde t_{n-2} denota la distribución t de Student con $n-2$ grados de libertad.

Con esta información, podemos construir ahora los intervalos de confianza para los parámetros b_0 y b_1, tal y como nos lo habíamos propuesto.

Empecemos por fijar un nivel de significancia α y sea $t_{\alpha/2,n-2}$ el cuantil superior de orden $\alpha/2$ de la distribución t de Student correspondientea.

Entonces, si tomamos $\hat{s}$ como el valor de la variable aleatoria $\hat{S}$ evaluada en el vector de datos observados $Y = y$, tenemos que los intervalos de confianza buscados son

$$(\hat{\beta}_0 - t_{\alpha/2,n-2}\hat{s}d_0, \hat{\beta}_0 + t_{\alpha/2,n-2}\hat{s}d_0)$$

para b_0, y

$$(\hat{\beta}_1 - t_{\alpha/2,n-2}\hat{s}d_1, \hat{\beta}_1 + t_{\alpha/2,n-2}\hat{s}d_1)$$

para b_1.

Bandas de confianza y de predicción

Una vez obtenidos los intervalos de confianza para los parámetros b_0 y b_1, nos gustaría obtener ahora los intervalos de confianza para los posibles valores de la variable dependiente Y_0 en un valor específico de la variable independiente $X_0 = x_0$.

Bandas de confianza y de predicción

Una vez obtenidos los intervalos de confianza para los parámetros b_0 y b_1, nos gustaría obtener ahora los intervalos de confianza para los posibles valores de la variable dependiente Y_0 en un valor específico de la variable independiente $X_0 = x_0$.

Para esto empezaremos por considerar la matriz de diseño en el punto x_0:

$$\Phi_0 = \begin{bmatrix} 1 & x_0 \end{bmatrix}$$

y definiremos el vector aleatorio

$$\hat{Y}_0 = \Phi_0 \hat{B} = \hat{B}_0 + \hat{B}_1 x_0$$

Notemos que este vector aleatorio depende solamente de las variables $\hat{B}_0$ y $\hat{B}_1$ (las cuales, a su vez, dependen solamente de las variables $Y_1, Y_2, \ldots, Y_n$), y es independiente de la variable aleatoria Y_0. Usando nuevamente las propiedades de la distribución normal multivariada, podemos ver que

$$\hat{Y}_0 \sim \mathcal{N}\left(\Phi_0 b, \sigma^2 d_c^2\right)$$

donde

$$d_c^2 = \Phi_0 D^2 \Phi_0^T = \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}$$

Finalmente, como $\hat{Y}_0$ es independiente de la variable aleatoria $\hat{S}^2$, podemos construir la variable aleatoria

$$T_c = \frac{\hat{Y}_0 - \Phi_0 b}{\hat{S} d_c} \sim t_{n-2}$$

Finalmente, como $\hat{Y}_0$ es independiente de la variable aleatoria $\hat{S}^2$, podemos construir la variable aleatoria

$$T_c = \frac{\hat{Y}_0 - \Phi_0 b}{\hat{S}d_c} \sim t_{n-2}$$

Se sigue que para construir un intervalo de confianza para el valor esperado de la variable dependiente Y_0 en el punto $X_0 = x_0$, basta con tomar el intervalo

$$(\hat{y}_0 - t_{\alpha/2,n-2}\hat{s}d_c, \hat{y}_0 + t_{\alpha/2,n-2}\hat{s}d_c)$$

donde $\hat{y}_0$ es el valor de la variable aleatoria $\hat{Y}_0$ evaluada en los datos observados $Y = y$.

Finalmente, como $\hat{Y}_0$ es independiente de la variable aleatoria $\hat{S}^2$, podemos construir la variable aleatoria

$$T_c = \frac{\hat{Y}_0 - \Phi_0 b}{\hat{S}d_c} \sim t_{n-2}$$

Se sigue que para construir un intervalo de confianza para el valor esperado de la variable dependiente Y_0 en el punto $X_0 = x_0$, basta con tomar el intervalo

$$(\hat{y}_0 - t_{\alpha/2,n-2}\hat{s}d_c, \hat{y}_0 + t_{\alpha/2,n-2}\hat{s}d_c)$$

donde $\hat{y}_0$ es el valor de la variable aleatoria $\hat{Y}_0$ evaluada en los datos observados $Y = y$.

Notemos que este intervalo depende del punto $X_0 = x_0$ que hayamos elegido.

Finalmente, como $\hat{Y}_0$ es independiente de la variable aleatoria $\hat{S}^2$, podemos construir la variable aleatoria

$$T_c = \frac{\hat{Y}_0 - \Phi_0 b}{\hat{S} d_c} \sim t_{n-2}$$

Se sigue que para construir un intervalo de confianza para el valor esperado de la variable dependiente Y_0 en el punto $X_0 = x_0$, basta con tomar el intervalo

$$(\hat{y}_0 - t_{\alpha/2,n-2}\hat{s}d_c, \hat{y}_0 + t_{\alpha/2,n-2}\hat{s}d_c)$$

donde $\hat{y}_0$ es el valor de la variable aleatoria $\hat{Y}_0$ evaluada en los datos observados $Y = y$.

Notemos que este intervalo depende del punto $X_0 = x_0$ que hayamos elegido.

De manera más general, podemos considerar el conjunto de todos los intervalos de confianza para todos los posibles valores de x_0, el cual se conoce como la **banda de confianza** del modelo de regresión lineal simple.

Para terminar, notemos que como Y_0 es independiente de $\hat{Y}_0$, tenemos que

$$Y_0 - \hat{Y}_0 \sim \mathcal{N}(0, \sigma^2 d_p^2)$$

donde

$$d_p^2 = 1 + d_c^2 = 1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}$$

Para terminar, notemos que como Y_0 es independiente de $\hat{Y}_0$, tenemos que

$$Y_0 - \hat{Y}_0 \sim \mathcal{N}(0, \sigma^2 d_p^2)$$

donde

$$d_p^2 = 1 + d_c^2 = 1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}$$

Usando nuevamente la variable aleatoria $\hat{S}^2$, podemos definir ahora

$$T_p = \frac{Y_0 - \hat{Y}_0}{\hat{S} d_p} \sim t_{n-2}$$

y, de manera similar a como lo hicimos antes, podemos construir un **intervalo de predicción** para el valor de la variable dependiente Y_0 en el punto $X_0 = x_0$ como

$$(\hat{y}_0 - t_{\alpha/2,n-2}\hat{s}d_p, \hat{y}_0 + t_{\alpha/2,n-2}\hat{s}d_p)$$

Nuevamente, el conjunto de todos estos intervalos de predicción para todos los posibles valores de x_0 se conoce como la **banda de predicción** del modelo de regresión lineal simple.