1 Estructura y organización de datos

MA2003B Aplicación de métodos multivariados
en ciencia de datos

Raul Gomez



Definición y propiedades básicas

Definition

Sea μ un vector (renglón) y Σ una matriz simétrica definida positiva. Decimos que un vector aleatorio (renglón) X tiene **distribución normal multivariante** con media μ y matriz de covarianzas Σ, en símbolos $X \sim \mathcal{N}_p(\mu, \Sigma)$, si su densidad es

$$\frac{1}{(2\pi)^{p/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(X-\mu)\Sigma^{-1}(X-\mu)^T\right) dX$$

Remark

Algunas observaciones sobre la definición:

1. Al igual que en el caso univariado, la normal multivariante queda completamente determinada por μ y Σ.

Remark

Algunas observaciones sobre la definición:

1. Al igual que en el caso univariado, la normal multivariante queda completamente determinada por μ y Σ.
2. La matriz Σ debe ser simétrica y definida positiva para que la distribución esté bien definida y el exponente sea negativo definido.

Remark

Algunas observaciones sobre la definición:

1. Al igual que en el caso univariado, la normal multivariante queda completamente determinada por μ y Σ.
2. La matriz Σ debe ser simétrica y definida positiva para que la distribución esté bien definida y el exponente sea negativo definido.
3. El término

$$|\Sigma| = \det(\Sigma)$$

es la **varianza generalizada** de la distribución. Puede interpretarse como una medida de la "dispersión" en el espacio de dimensión p.

Remark

Algunas observaciones sobre la definición:

1. Al igual que en el caso univariado, la normal multivariante queda completamente determinada por μ y Σ.
2. La matriz Σ debe ser simétrica y definida positiva para que la distribución esté bien definida y el exponente sea negativo definido.
3. El término
$$|\Sigma| = \det(\Sigma)$$
es la **varianza generalizada** de la distribución. Puede interpretarse como una medida de la "dispersión" en el espacio de dimensión p.
4. El término $(X-\mu)\Sigma^{-1}(X-\mu)^T$ es el cuadrado de la distancia de Mahalanobis entre X y la media μ.

Como en el caso univariado, la normal multivariante es destacada por el Teorema Central del Límite, que a grandes rasgos dice que la suma de muchas variables i.i.d. (debidamente estandarizadas) converge a una normal.

Teorema central del límite (multivariante)

Theorem

Sea $\{X_i\}_{i=1}^{\infty}$ una sucesión de vectores aleatorios i.i.d. en $\mathbb{R}^p$ con media μ y covarianzas Σ. Defina la media muestral

$$\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i.$$

Entonces, cuando $n \to \infty$,

$$\sqrt{n}\,(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}_p(0, \Sigma),$$

donde $\xrightarrow{d}$ denota convergencia en distribución y $\mathcal{N}_p(0,\Sigma)$ es la normal multivariante de dimensión p con media 0 y covarianzas Σ.

Remark

Aun cuando el TCL destaca a la normal multivariante como especialmente importante, no es la única distribución relevante en estadística multivariante.

Remark

Aun cuando el TCL destaca a la normal multivariante como especialmente importante, no es la única distribución relevante en estadística multivariante.

De hecho, la mayoría de los datos reales no siguen una normal, y muchos métodos están diseñados para datos no normales.

Remark

Aun cuando el TCL destaca a la normal multivariante como especialmente importante, no es la única distribución relevante en estadística multivariante.

De hecho, la mayoría de los datos reales no siguen una normal, y muchos métodos están diseñados para datos no normales.

Además, métodos importantes como regresión lineal, ACP y clustering no producen buenos resultados cuando se aplican a una normal multivariante.

Contornos de la normal multivariante

Observe que la función de densidad de la normal multivariante es gaussiana en p dimensiones.

Contornos de la normal multivariante

Observe que la función de densidad de la normal multivariante es gaussiana en p dimensiones.

Esto implica que los contornos son elipsoides centrados en μ y cuya forma está controlada por Σ.

Contornos de la normal multivariante

Observe que la función de densidad de la normal multivariante es gaussiana en p dimensiones.

Esto implica que los contornos son elipsoides centrados en μ y cuya forma está controlada por Σ.

La probabilidad asociada a estos contornos está controlada por la distribución χ^2 en el siguiente sentido:

Sea $0 \leq \varpi \leq 1$ un nivel de probabilidad, y sea c tal que

$$\mathbb{P}(\chi_p^2 \leq c) = \varpi$$

Sea $0 \leq \varpi \leq 1$ un nivel de probabilidad, y sea c tal que

$$\mathbb{P}(\chi_p^2 \leq c) = \varpi$$

Entonces, el contorno que contiene una proporción ϖ de la masa de probabilidad está dado por los puntos X que satisfacen

$$(X - \mu)\Sigma^{-1}(X - \mu)^T = c$$

En la siguiente figura mostramos los contornos de la normal bivariante con distintas matrices de covarianzas.

En la siguiente figura mostramos los contornos de la normal bivariante con distintas matrices de covarianzas.

Los contornos son elipses centradas en $\mu = (0,0)$, y su forma está determinada por Σ.

En la siguiente figura mostramos los contornos de la normal bivariante con distintas matrices de covarianzas.

Los contornos son elipses centradas en $\mu = (0,0)$, y su forma está determinada por Σ.

El gradiente de color representa la densidad: colores más oscuros indican mayor densidad.

Contornos de la normal bivariante

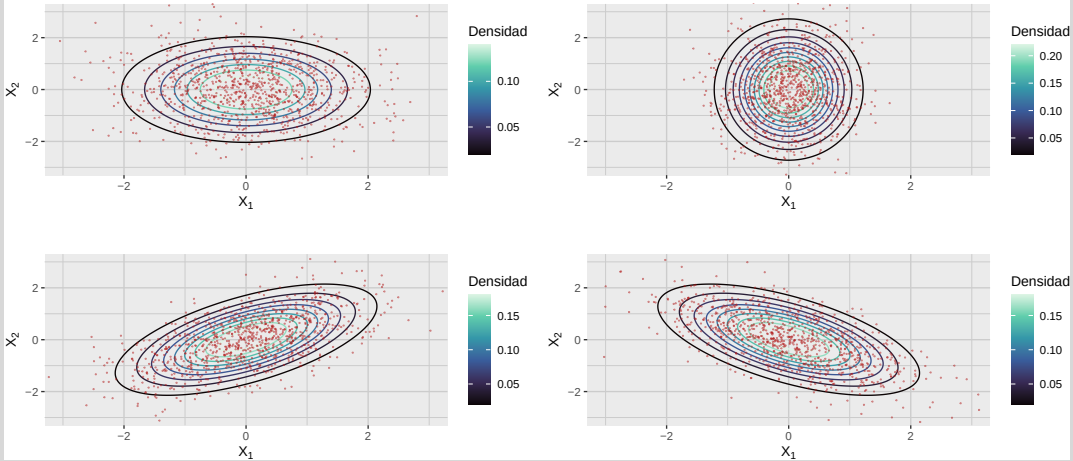


Figure 1: Distribución normal bivariante con distintas matrices de covarianzas

Estandarización de la distribución normal multivariante

Al igual que en el caso univariado, dado $X \sim \mathcal{N}_p(\mu, \Sigma)$, podemos estandarizarlo para obtener $Z \sim \mathcal{N}_p(0, I_p)$, donde I_p es la identidad de tamaño p.

Estandarización de la distribución normal multivariante

Al igual que en el caso univariado, dado $X \sim \mathcal{N}_p(\mu, \Sigma)$, podemos estandarizarlo para obtener $Z \sim \mathcal{N}_p(0, I_p)$, donde I_p es la identidad de tamaño p.

Para describir este proceso, recordemos algunos resultados de álgebra lineal.

Singular Value Decomposition

Theorem

Sea Σ simétrica definida positiva de tamaño $p \times p$. Entonces existe una matriz ortogonal Q y una diagonal Λ con entradas positivas tales que

$$\Sigma = Q\Lambda Q^T$$

Singular Value Decomposition

Theorem

Sea Σ simétrica definida positiva de tamaño $p \times p$. Entonces existe una matriz ortogonal Q y una diagonal Λ con entradas positivas tales que

$$\Sigma = Q\Lambda Q^T$$

Remark

Recuerde que Q es ortogonal si $Q^T Q = I_p$, donde I_p es la identidad de tamaño p. Sus columnas son ortonormales y forman una base de $\mathbb{R}^p$.

Remark

La descomposición en valores singulares (SVD) es una herramienta que descompone una matriz en partes constitutivas.

Remark

La descomposición en valores singulares (SVD) es una herramienta que descompone una matriz en partes constitutivas.

Para Σ, la SVD la expresa en términos de sus **valores singulares** (entradas diagonales de Λ, también llamados **autovalores**) y sus **vectores singulares** (columnas de Q, también llamados **autovectores**).

Remark

La descomposición en valores singulares (SVD) es una herramienta que descompone una matriz en partes constitutivas.

Para Σ, la SVD la expresa en términos de sus **valores singulares** (entradas diagonales de Λ, también llamados **autovalores**) y sus **vectores singulares** (columnas de Q, también llamados **autovectores**).

Esta descomposición es muy útil para entender la geometría de la normal multivariante.

Obsérvese que, como Σ es definida positiva, las entradas diagonales de

$$\Lambda = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_p \end{bmatrix}$$

son todas positivas.

Obsérvese que, como Σ es definida positiva, las entradas diagonales de

$$\Lambda = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_p \end{bmatrix}$$

son todas positivas.

En particular, podemos definir la matriz

$$D = \begin{bmatrix} \sqrt{\lambda_1} & 0 & \cdots & 0 \\ 0 & \sqrt{\lambda_2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sqrt{\lambda_p} \end{bmatrix}$$

que satisface $D^2 = \Lambda$.

Si ahora tomamos

$$\sigma = DQ^T$$

Si ahora tomamos

$$\sigma = DQ^T$$

entonces

$$\Sigma = \sigma^T \sigma$$

Si ahora tomamos

$$\sigma = DQ^T$$

entonces

$$\Sigma = \sigma^T \sigma$$

En particular, podemos definir la **estandarización** de X como

$$Z = (X - \mu)\sigma^{-1} = (X - \mu)QD^{-1} = (X - \mu)Q\Lambda^{-1/2}$$

in which case $Z \sim \mathcal{N}_p(0, I_p)$.

Interpretación geométrica de la SVD

Antes consideramos la normal multivariante con media

$$\mu = [0,0]$$

y matriz de covarianzas

$$\Sigma = \begin{bmatrix} 1 & 0.6 \\ 0.6 & 1 \end{bmatrix}$$

Interpretación geométrica de la SVD

Antes consideramos la normal multivariante con media

$$\mu = [0,0]$$

y matriz de covarianzas

$$\Sigma = \begin{bmatrix} 1 & 0.6 \\ 0.6 & 1 \end{bmatrix}$$

Según la SVD, podemos escribir esta matriz de covarianzas como

$$\Sigma = Q\Lambda Q^T$$

for some orthogonal matrix Q and diagonal matrix Λ.

En este caso obtenemos:

$$Q = \begin{bmatrix} 0.7071068 & -0.7071068 \\ 0.7071068 & 0.7071068 \end{bmatrix}$$

y

$$\Lambda = \begin{bmatrix} 1.6 & 0 \\ 0 & 0.4 \end{bmatrix}$$

en donde los vectores singulares son las columnas de Q y los valores singulares son las entradas diagonales de Λ.

En este caso obtenemos:

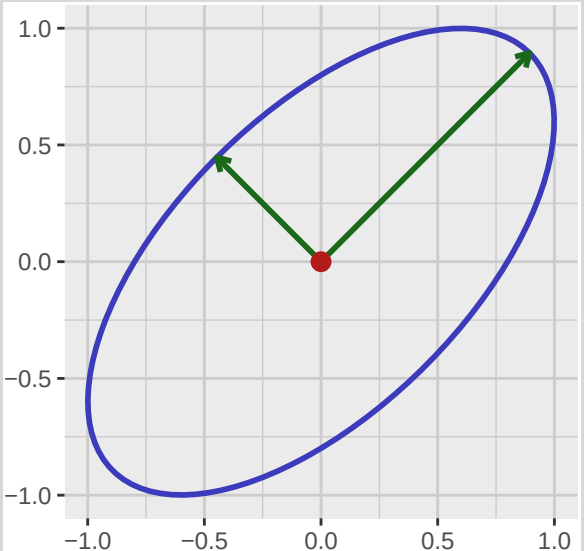
$$Q = \begin{bmatrix} 0.7071068 & -0.7071068 \\ 0.7071068 & 0.7071068 \end{bmatrix}$$

y

$$\Lambda = \begin{bmatrix} 1.6 & 0 \\ 0 & 0.4 \end{bmatrix}$$

en donde los vectores singulares son las columnas de Q y los valores singulares son las entradas diagonales de Λ.

Geometrically, the singular vectors represent the directions of the axes of the ellipsoid that defines the contours of the normal multivariate distribution, and the square root of the singular values represent the lengths of these axes.


1.0
0.5
0.0
−0.5
−1.0
−1.0
−0.5
0.0
0.5
1.0

Clausura bajo transformaciones lineales

Theorem

Sea $X \sim \mathcal{N}_p(\mu, \Sigma)$. Para cualquier matriz A de tamaño $m \times p$ y vector b de tamaño m, el vector aleatorio

$$Y = AX + b$$

también tiene distribución normal multivariante: $Y \sim \mathcal{N}_m(A\mu + b, A\Sigma A^T)$.

Remark

El teorema dice que si aplicamos una transformación lineal a un vector normal multivariante, el resultado es también normal multivariante.

Remark

El teorema dice que si aplicamos una transformación lineal a un vector normal multivariante, el resultado es también normal multivariante.

La media y la covarianza del transformado vienen dadas por las fórmulas del teorema.

Remark

El teorema dice que si aplicamos una transformación lineal a un vector normal multivariante, el resultado es también normal multivariante.

La media y la covarianza del transformado vienen dadas por las fórmulas del teorema.

Es útil en aplicaciones como regresión, donde transformamos datos preservando la normalidad de residuales.

Remark

El teorema dice que si aplicamos una transformación lineal a un vector normal multivariante, el resultado es también normal multivariante.

La media y la covarianza del transformado vienen dadas por las fórmulas del teorema.

Es útil en aplicaciones como regresión, donde transformamos datos preservando la normalidad de residuales.

En la práctica se usa para derivar la distribución de combinaciones lineales de variables aleatorias.

Example

Sea $X \sim \mathcal{N}_2(\mu, \Sigma)$ con media $\mu = (1,2)$ y matriz de covarianzas

$$\Sigma = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 2 \end{bmatrix}$$

Example

Sea $X \sim \mathcal{N}_2(\mu, \Sigma)$ con media $\mu = (1,2)$ y matriz de covarianzas

$$\Sigma = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 2 \end{bmatrix}$$

Ahora, considere la transformación lineal

$$Y = \begin{bmatrix} 2 & 1 \\ 0 & 3 \end{bmatrix} X + \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

Example

Sea $X \sim \mathcal{N}_2(\mu, \Sigma)$ con media $\mu = (1,2)$ y matriz de covarianzas

$$\Sigma = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 2 \end{bmatrix}$$

Ahora, considere la transformación lineal

$$Y = \begin{bmatrix} 2 & 1 \\ 0 & 3 \end{bmatrix} X + \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

En otras palabras,

$$Y_1 = 2X_1 + X_2$$
$$Y_2 = 3X_2 + 1-$$

Example

Usando la clausura bajo transformaciones lineales, obtenemos media y covarianzas de Y:

$$\text{Mean: } A\mu + b = \begin{bmatrix} 2 & 1 \\ 0 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 4 \\ 7 \end{bmatrix}$$

$$\text{Covariance: } A\Sigma A^T = \begin{bmatrix} 2 & 1 \\ 0 & 3 \end{bmatrix} \begin{bmatrix} 1 & 0.5 \\ 0.5 & 2 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 1 & 3 \end{bmatrix} = \begin{bmatrix} 8 & 9 \\ 9 & 18 \end{bmatrix}$$

Example

Usando la clausura bajo transformaciones lineales, obtenemos media y covarianzas de Y:

$$\text{Mean: } A\mu + b = \begin{bmatrix} 2 & 1 \\ 0 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 4 \\ 7 \end{bmatrix}$$

$$\text{Covariance: } A\Sigma A^T = \begin{bmatrix} 2 & 1 \\ 0 & 3 \end{bmatrix} \begin{bmatrix} 1 & 0.5 \\ 0.5 & 2 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 1 & 3 \end{bmatrix} = \begin{bmatrix} 8 & 9 \\ 9 & 18 \end{bmatrix}$$

Así,

$$Y \sim \mathcal{N}_2 \left(\begin{bmatrix} 4 \\ 7 \end{bmatrix}, \begin{bmatrix} 8 & 9 \\ 9 & 18 \end{bmatrix} \right)$$

Remark

Nótese que proyectar a un subespacio es lineal; por tanto, cualquier subconjunto de componentes de una normal multivariante también es normal multivariante.

Remark

Nótese que proyectar a un subespacio es lineal; por tanto, cualquier subconjunto de componentes de una normal multivariante también es normal multivariante.

Esta propiedad permite analizar subconjuntos de variables manteniendo la suposición de normalidad.

Pruebas de normalidad multivariante

Existen varias pruebas para verificar si un conjunto de datos sigue una normal multivariante. Son esenciales porque muchos métodos asumen normalidad. Algunas comunes y su implementación en R:

1. **Prueba de Mardia:** Basada en asimetría y curtosis multivariantes. Para normal multivariante, asimetría ≈ 0 y curtosis $\approx p(p+2)$. En R: `MVN::mvn(tus_datos, mvn_test = "mardia")`.
2. **Prueba de Henze–Zirkler (HZ):** Usa la función característica empírica para medir desvíos de normalidad. Buen poder global; adecuada en dimensiones moderadas. En R: `MVN::mvn(tus_datos, mvn_test = "hz")`.

3. **Prueba de Royston:** Extensión multivariante de Shapiro–Wilk (producto de estadísticas univariadas aplicado a componentes principales). Fácil de interpretar; pierde poder en alta dimensión. En R: `MVN::mvn(tus_datos, mvn_test = "royston")`.
4. **Prueba de Doornik–Hansen:** Combina asimetría y curtosis en una prueba ómnibus, alternativa robusta a Mardia. En R: `MVN::mvn(tus_datos, mvn_test = "dh")`.
5. **Métodos gráficos (Q–Q de chi-cuadrada):** Graficar distancias de Mahalanobis contra cuantiles de χ^2. Desviaciones de la recta indican no normalidad. En R: `multivariate_diagnostic_plot(data = tus_datos, type = "qq")`.