

Selección de variables en el modelo LDA

MA2003B Aplicación de métodos multivariados
en ciencia de datos

Raul Gomez



Tecnológico
de Monterrey

Selección de variables para Análisis Discriminante Lineal

El Análisis Discriminante Lineal (LDA) permite clasificar observaciones en grupos utilizando un conjunto de variables predictoras.

Selección de variables para Análisis Discriminante Lineal

El Análisis Discriminante Lineal (LDA) permite clasificar observaciones en grupos utilizando un conjunto de variables predictoras.

Sin embargo, no todas las variables disponibles necesariamente contienen información útil para distinguir entre los grupos.

Selección de variables para Análisis Discriminante Lineal

El Análisis Discriminante Lineal (LDA) permite clasificar observaciones en grupos utilizando un conjunto de variables predictoras.

Sin embargo, no todas las variables disponibles necesariamente contienen información útil para distinguir entre los grupos.

Eliminar variables irrelevantes puede simplificar el modelo, disminuir el ruido y facilitar su interpretación.

Criterio de selección

Supongamos que tenemos una variable categórica G que puede tomar K valores distintos.

Criterio de selección

Supongamos que tenemos una variable categórica G que puede tomar K valores distintos.

Consideremos una variable predictora X_j

Criterio de selección

Supongamos que tenemos una variable categórica G que puede tomar K valores distintos.

Consideremos una variable predictora X_j

Para determinar si X_j contiene información que permita distinguir entre los grupos, podemos comparar sus medias mediante un ANOVA de una vía.

Criterio de selección

Supongamos que tenemos una variable categórica G que puede tomar K valores distintos.

Consideremos una variable predictora X_j

Para determinar si X_j contiene información que permita distinguir entre los grupos, podemos comparar sus medias mediante un ANOVA de una vía.

Las hipótesis son

$$H_0 : \mu_{1j} = \mu_{2j} = \cdots = \mu_{Kj},$$

contra

$$H_1 : \text{al menos una de las medias es diferente.}$$

El procedimiento se aplica **por separado a cada variable predictora**.

El procedimiento se aplica **por separado a cada variable predictora**.

Elegimos un nivel de significancia α .

El procedimiento se aplica **por separado a cada variable predictora**.

Elegimos un nivel de significancia α .

Para cada variable X_j :

El procedimiento se aplica **por separado a cada variable predictora**.

Elegimos un nivel de significancia α .

Para cada variable X_j :

1. realizamos un ANOVA de una vía;

El procedimiento se aplica **por separado a cada variable predictora**.

Elegimos un nivel de significancia α .

Para cada variable X_j :

1. realizamos un ANOVA de una vía;
2. obtenemos el valor p correspondiente;

El procedimiento se aplica **por separado a cada variable predictora**.

Elegimos un nivel de significancia α .

Para cada variable X_j :

1. realizamos un ANOVA de una vía;
2. obtenemos el valor p correspondiente;
3. si $p \leq \alpha$, conservamos la variable;

El procedimiento se aplica **por separado a cada variable predictora**.

Elegimos un nivel de significancia α .

Para cada variable X_j :

1. realizamos un ANOVA de una vía;
2. obtenemos el valor p correspondiente;
3. si $p \leq \alpha$, conservamos la variable;
4. si $p > \alpha$, eliminamos la variable.

El procedimiento se aplica **por separado a cada variable predictora**.

Elegimos un nivel de significancia α .

Para cada variable X_j :

1. realizamos un ANOVA de una vía;
2. obtenemos el valor p correspondiente;
3. si $p \leq \alpha$, conservamos la variable;
4. si $p > \alpha$, eliminamos la variable.

Por lo tanto, no realizamos una MANOVA: utilizamos un ANOVA independiente como filtro para cada predictor.

Flujo recomendado

Para realizar la selección de variables y ajustar el modelo LDA utilizaremos el siguiente flujo:

Flujo recomendado

Para realizar la selección de variables y ajustar el modelo LDA utilizaremos el siguiente flujo:

1. **Partición de los datos** en entrenamiento y prueba.

Flujo recomendado

Para realizar la selección de variables y ajustar el modelo LDA utilizaremos el siguiente flujo:

1. **Partición de los datos** en entrenamiento y prueba.
2. **Verificación de los supuestos** del modelo LDA.

Flujo recomendado

Para realizar la selección de variables y ajustar el modelo LDA utilizaremos el siguiente flujo:

1. **Partición de los datos** en entrenamiento y prueba.
2. **Verificación de los supuestos** del modelo LDA.
3. **Selección de variables mediante ANOVA.**

Flujo recomendado

Para realizar la selección de variables y ajustar el modelo LDA utilizaremos el siguiente flujo:

1. **Partición de los datos** en entrenamiento y prueba.
2. **Verificación de los supuestos** del modelo LDA.
3. **Selección de variables mediante ANOVA.**
4. **Construcción del workflow** con la receta y el modelo LDA.

Flujo recomendado

Para realizar la selección de variables y ajustar el modelo LDA utilizaremos el siguiente flujo:

1. **Partición de los datos** en entrenamiento y prueba.
2. **Verificación de los supuestos** del modelo LDA.
3. **Selección de variables mediante ANOVA.**
4. **Construcción del workflow** con la receta y el modelo LDA.
5. **Validación cruzada** sobre los datos de entrenamiento.

Flujo recomendado

Para realizar la selección de variables y ajustar el modelo LDA utilizaremos el siguiente flujo:

1. **Partición de los datos** en entrenamiento y prueba.
2. **Verificación de los supuestos** del modelo LDA.
3. **Selección de variables mediante ANOVA.**
4. **Construcción del workflow** con la receta y el modelo LDA.
5. **Validación cruzada** sobre los datos de entrenamiento.
6. **Ajuste del modelo final.**

Flujo recomendado

Para realizar la selección de variables y ajustar el modelo LDA utilizaremos el siguiente flujo:

1. **Partición de los datos** en entrenamiento y prueba.
2. **Verificación de los supuestos** del modelo LDA.
3. **Selección de variables mediante ANOVA.**
4. **Construcción del workflow** con la receta y el modelo LDA.
5. **Validación cruzada** sobre los datos de entrenamiento.
6. **Ajuste del modelo final.**
7. **Evaluación final** sobre los datos de prueba.

Supuestos del modelo LDA

El modelo LDA clásico supone que, dentro de cada grupo,

$$X \mid G = k \sim N_p(\mu_k, \Sigma),$$

donde todos los grupos comparten la misma matriz de covarianzas Σ .

Supuestos del modelo LDA

El modelo LDA clásico supone que, dentro de cada grupo,

$$X \mid G = k \sim N_p(\mu_k, \Sigma),$$

donde todos los grupos comparten la misma matriz de covarianzas Σ .

Por lo tanto, verificamos:

Supuestos del modelo LDA

El modelo LDA clásico supone que, dentro de cada grupo,

$$X \mid G = k \sim N_p(\mu_k, \Sigma),$$

donde todos los grupos comparten la misma matriz de covarianzas Σ .

Por lo tanto, verificamos:

1. **normalidad multivariada** dentro de cada grupo;

Supuestos del modelo LDA

El modelo LDA clásico supone que, dentro de cada grupo,

$$X \mid G = k \sim N_p(\mu_k, \Sigma),$$

donde todos los grupos comparten la misma matriz de covarianzas Σ .

Por lo tanto, verificamos:

1. **normalidad multivariada** dentro de cada grupo;
2. **igualdad de las matrices de covarianzas** entre los grupos.

Supuestos del modelo LDA

El modelo LDA clásico supone que, dentro de cada grupo,

$$X \mid G = k \sim N_p(\mu_k, \Sigma),$$

donde todos los grupos comparten la misma matriz de covarianzas Σ .

Por lo tanto, verificamos:

1. **normalidad multivariada** dentro de cada grupo;
2. **igualdad de las matrices de covarianzas** entre los grupos.

La independencia de las observaciones depende del proceso de generación o muestreo. En este ejemplo sintético, las observaciones fueron generadas independientemente.

Normalidad multivariada

Para evaluar la normalidad multivariada aplicamos la prueba de Henze–Zirkler por separado dentro de cada grupo.

Normalidad multivariada

Para evaluar la normalidad multivariada aplicamos la prueba de Henze–Zirkler por separado dentro de cada grupo.

Las hipótesis son

H_0 : el vector de predictores sigue una distribución normal multivariada,

H_1 : el vector de predictores no sigue una distribución normal multivariada.

Normalidad multivariada

Para evaluar la normalidad multivariada aplicamos la prueba de Henze–Zirkler por separado dentro de cada grupo.

Las hipótesis son

H_0 : el vector de predictores sigue una distribución normal multivariada,

H_1 : el vector de predictores no sigue una distribución normal multivariada.

Utilizamos un nivel de significancia de α dado.

Igualdad de matrices de covarianzas

Para comparar las matrices de covarianzas utilizamos la prueba de Box (M).

Igualdad de matrices de covarianzas

Para comparar las matrices de covarianzas utilizamos la prueba de Box (M).

Las hipótesis son

H_0 : todas las matrices de covarianzas poblacionales son iguales

contra la alternativa de que al menos una matriz de covarianzas poblacional es diferente.

Igualdad de matrices de covarianzas

Para comparar las matrices de covarianzas utilizamos la prueba de Box (M).

Las hipótesis son

H_0 : todas las matrices de covarianzas poblacionales son iguales

contra la alternativa de que al menos una matriz de covarianzas poblacional es diferente.

Utilizamos un nivel de significancia de α previamente dado.