

Selección de variables en el modelo LDA

MA2003B Aplicación de métodos multivariados
en ciencia de datos

Raul Gomez



Tecnológico
de Monterrey

El modelo logístico

En el método de regresión logística, buscamos clasificar las observaciones dadas en dos categorías (usualmente etiquetadas como 0 y 1) basándonos en una o más variables predictoras.

El modelo logístico

En el método de regresión logística, buscamos clasificar las observaciones dadas en dos categorías (usualmente etiquetadas como 0 y 1) basándonos en una o más variables predictoras.

A diferencia de la regresión lineal, que predice valores continuos, la regresión logística predice la probabilidad de que una observación pertenezca a una categoría específica.

El modelo logístico

En el método de regresión logística, buscamos clasificar las observaciones dadas en dos categorías (usualmente etiquetadas como 0 y 1) basándonos en una o más variables predictoras.

A diferencia de la regresión lineal, que predice valores continuos, la regresión logística predice la probabilidad de que una observación pertenezca a una categoría específica.

Una vez que hemos determinado estas probabilidades, podemos utilizar el teorema de clasificación de Bayes para asignar cada observación a la categoría más probable.

El modelo logístico

En el método de regresión logística, buscamos clasificar las observaciones dadas en dos categorías (usualmente etiquetadas como 0 y 1) basándonos en una o más variables predictoras.

A diferencia de la regresión lineal, que predice valores continuos, la regresión logística predice la probabilidad de que una observación pertenezca a una categoría específica.

Una vez que hemos determinado estas probabilidades, podemos utilizar el teorema de clasificación de Bayes para asignar cada observación a la categoría más probable.

Notemos que el objetivo principal de este método es similar al del Análisis Discriminante Lineal (LDA), pero la regresión logística no asume que las variables predictoras sigan una distribución normal, lo que la hace más flexible en ciertos contextos.

La función logística y la función logit

Recordemos que la **función logística** está definida como:

$$p = h(z) = \frac{1}{1 + e^{-z}}$$

y proporciona una biyección entre los números reales y el intervalo $(0, 1)$.

La función logística y la función logit


Recordemos que la **función logística** está definida como:

$$p = h(z) = \frac{1}{1 + e^{-z}}$$

y proporciona una biyección entre los números reales y el intervalo $(0, 1)$.

Dado que las probabilidades de un evento siempre se encuentran en este intervalo, la función logística es ideal para modelar probabilidades.

La función logística



Notemos que en la definición de la función logística podemos despejar z en términos de p .


Notemos que en la definición de la función logística podemos despejar z en términos de p .

Haciendo esto, obtenemos la **función logit**, definida como:

$$z = h^{-1}(p) = \log \left(\frac{p}{1-p} \right)$$

La función logit transforma probabilidades (valores entre 0 y 1) en valores reales, lo que es útil para modelar relaciones lineales en el contexto de la regresión logística.

La función logit



El clasificador logístico

Ahora supongamos que tenemos una variable de respuesta Y_0 que puede tomar solamente dos valores. (Usualmente, estos valores son 0 y 1.)

El clasificador logístico

Ahora supongamos que tenemos una variable de respuesta Y_0 que puede tomar solamente dos valores. (Usualmente, estos valores son 0 y 1.)

Supongamos además que la relación de esta variable con un vector de variables predictoras

$$X_0 = \begin{bmatrix} X_{01} \\ X_{02} \\ \vdots \\ X_{0p} \end{bmatrix}$$

está dada por la condición

$$Y_0 | (X_0 = x_0) \sim \text{Bernoulli}(p)$$

donde $p = P(Y_0 = 1 | X_0 = x_0)$.

En el modelo de regresión logística, suponemos que el logit de p depende linealmente de las variables predictoras, es decir,

$$z = \log \left(\frac{p}{1-p} \right) = b_0 + b_1 x_{01} + b_2 x_{02} + \cdots + b_p x_{0p}$$

para algunos parámetros $b_0, b_1, \dots, b_p$.

En el modelo de regresión logística, suponemos que el logit de p depende linealmente de las variables predictoras, es decir,

$$z = \log \left(\frac{p}{1-p} \right) = b_0 + b_1 x_{01} + b_2 x_{02} + \cdots + b_p x_{0p}$$

para algunos parámetros $b_0, b_1, \dots, b_p$.

Usando la función logística, podemos expresar p en términos de las variables predictoras como

$$p = h(z) = \frac{1}{1 + e^{-(b_0 + b_1 x_{01} + b_2 x_{02} + \cdots + b_p x_{0p})}}$$

Notemos que el cociente

$$\frac{p}{1-p} = e^{b_0 + b_1 x_{01} + b_2 x_{02} + \dots + b_p x_{0p}}$$

conocido como la **oportunidad** o **momio** (también conocido como **odds** en inglés) satisface la siguiente condición: por cada unidad que aumente la variable predictora X_{0j} (manteniendo las demás variables constantes), la oportunidad se multiplica por un factor de e^{b_j} .

Notemos que el cociente

$$\frac{p}{1-p} = e^{b_0 + b_1 x_{01} + b_2 x_{02} + \dots + b_p x_{0p}}$$

conocido como la **oportunidad** o **momio** (también conocido como **odds** en inglés) satisface la siguiente condición: por cada unidad que aumente la variable predictora X_{0j} (manteniendo las demás variables constantes), la oportunidad se multiplica por un factor de e^{b_j} .

Esta propiedad hace que la regresión logística sea especialmente útil para interpretar el impacto de cada variable predictora en la probabilidad del evento de interés.

Para definir el **clasificador logístico**, fijamos un umbral de probabilidad $\tau \in (0, 1)$. Entonces, asignamos una observación al grupo 1 si la probabilidad estimada p es mayor o igual a τ , y al grupo 0 en caso contrario.

Para definir el **clasificador logístico**, fijamos un umbral de probabilidad $\tau \in (0, 1)$. Entonces, asignamos una observación al grupo 1 si la probabilidad estimada p es mayor o igual a τ , y al grupo 0 en caso contrario.

En la práctica, un valor comúnmente utilizado para τ es 0.5, lo que significa que asignamos una observación al grupo 1 si la probabilidad estimada de pertenecer a ese grupo es al menos del 50%.

Para definir el **clasificador logístico**, fijamos un umbral de probabilidad $\tau \in (0, 1)$. Entonces, asignamos una observación al grupo 1 si la probabilidad estimada p es mayor o igual a τ , y al grupo 0 en caso contrario.

En la práctica, un valor comúnmente utilizado para τ es 0.5, lo que significa que asignamos una observación al grupo 1 si la probabilidad estimada de pertenecer a ese grupo es al menos del 50%.

Sin embargo, este umbral puede ajustarse según las necesidades específicas del análisis o las consecuencias de los errores de clasificación.

Para definir el **clasificador logístico**, fijamos un umbral de probabilidad $\tau \in (0, 1)$. Entonces, asignamos una observación al grupo 1 si la probabilidad estimada p es mayor o igual a τ , y al grupo 0 en caso contrario.

En la práctica, un valor comúnmente utilizado para τ es 0.5, lo que significa que asignamos una observación al grupo 1 si la probabilidad estimada de pertenecer a ese grupo es al menos del 50%.

Sin embargo, este umbral puede ajustarse según las necesidades específicas del análisis o las consecuencias de los errores de clasificación.

Notemos además que en este caso, la frontera de decisión está dada por

$$\log \left(\frac{\tau}{1 - \tau} \right) = 0 = b_0 + b_1 x_{01} + b_2 x_{02} + \cdots + b_p x_{0p}$$

Como ejemplo, consideremos el caso en el que tenemos dos variables predictoras ($p = 2$) y los parámetros $b_0 = 0$, $b_1 = 4$ y $b_2 = 4$.

Como ejemplo, consideremos el caso en el que tenemos dos variables predictoras ($p = 2$) y los parámetros $b_0 = 0$, $b_1 = 4$ y $b_2 = 4$.

En este caso, la frontera de decisión para un umbral $\tau = 0.5$ está dada por la ecuación

$$0 + 4 \cdot x_{01} + 4 \cdot x_{02} = 0$$

$$x_{02} = -x_{01}$$

Como ejemplo, consideremos el caso en el que tenemos dos variables predictoras ($p = 2$) y los parámetros $b_0 = 0$, $b_1 = 4$ y $b_2 = 4$.

En este caso, la frontera de decisión para un umbral $\tau = 0.5$ está dada por la ecuación

$$0 + 4 \cdot x_{01} + 4 \cdot x_{02} = 0$$

$$x_{02} = -x_{01}$$

Para visualizar esta frontera, podemos simular un conjunto de observaciones y clasificar cada punto con el modelo logístico.

Como ejemplo, consideremos el caso en el que tenemos dos variables predictoras ($p = 2$) y los parámetros $b_0 = 0$, $b_1 = 4$ y $b_2 = 4$.


En este caso, la frontera de decisión para un umbral $\tau = 0.5$ está dada por la ecuación

$$\begin{aligned}0 + 4 \cdot x_{01} + 4 \cdot x_{02} &= 0 \\ x_{02} &= -x_{01}\end{aligned}$$

Para visualizar esta frontera, podemos simular un conjunto de observaciones y clasificar cada punto con el modelo logístico.

Usaremos $b_0 = 0$, $b_1 = b_2 = 4$, $\tau = 0.5$ y generaremos 1,000 observaciones para x_1 y x_2 con distribución uniforme en $[-1, 1]$.

Ejemplo del clasificador logístico



Notemos que la clasificación no es perfecta, sin embargo el número de errores decrece de manera exponencial a medida que nos alejamos de la frontera de decisión.

Notemos que la clasificación no es perfecta, sin embargo el número de errores decrece de manera exponencial a medida que nos alejamos de la frontera de decisión.

Si calculamos la matriz de confusión para este clasificador logístico simulado, obtenemos:

Table 1: Matriz de confusión para el clasificador logístico simulado.

Verdadero \ Predicción	Grupo 0	Grupo 1
Grupo 0	409	91
Grupo 1	93	407