



Tecnológico de Monterrey

Aplicación de Métodos Multivariados en Ciencia de Datos

Módulo 2: Relaciones de Dependencia

Raúl Gómez Muñoz
Blanca Rosa Ruiz Hernández

Tabla de contenidos

I Análisis de regresión lineal

1. Inferencia univariada	1
1.1. Estimación de la media por intervalos	1
1.2. Pruebas de hipótesis para la media	10
2. Regresión lineal simple	11
2.1. El modelo de regresión lineal simple	11
2.2. Estimación de parámetros por intervalos de confianza	13
2.3. Bandas de confianza y de predicción	14
2.4. Ejemplo de construcción de bandas de confianza y de predicción	15
3. Regresión lineal múltiple	25
3.1. Ajuste del modelo de regresión lineal múltiple	25
3.2. Evaluación del modelo ajustado	27
3.2.1. Máxima verosimilitud	27
3.2.2. Significancia del modelo y de los parámetros	29

II Análisis discriminante lineal

4. El modelo discriminante gaussiano	33
4.1. El clasificador bayesiano	33
4.2. Las funciones discriminantes lineales	34
4.3. Las variables canónicas	35
5. Ajuste y adecuación del modelo discriminante gaussiano	37
5.1. Ajuste del modelo discriminante gaussiano	37
5.1.1. El método de estimación de Fisher (FE)	37
5.1.2. El método de máxima verosimilitud (MLE)	38
5.1.3. Comparación de los enfoques FE y MLE	39
5.2. Verificación de la adecuación del modelo discriminante gaussiano	39
5.2.1. Pruebas de normalidad multivariada	39
5.2.2. Pruebas de Homoscedasticidad	40
5.2.3. Evaluación del rendimiento del modelo	40
5.3. Modelos alternativos	40

6. Método LDA paso a paso para la selección de variables	41
6.1. Criterio de selección	41
6.2. Flujo recomendado	42
6.3. Ejemplo ilustrativo	42
6.3.1. Preparación de datos	42
6.3.2. Aplicación de <code>stepclass()</code>	43
6.3.3. Ajuste del modelo final	44
6.3.4. Evaluación del modelo	45
6.3.5. Verificación de supuestos	47
6.3.6. Interpretación y reporte	50
 III Regresión logística	 51
7. El modelo logístico	53
7.1. La función logística y la función logit	53
7.2. El clasificador logístico	57
 8. Ajuste y adecuación del modelo de regresión logística	 61
8.1. Ajuste del modelo de regresión logística	61
8.2. Adecuación del modelo de regresión logística	62
8.2.1. Prueba de razón de verosimilitudes	62
8.2.2. Análisis de residuos	62
8.2.3. Curvas ROC y AUC	63

Parte I

Análisis de regresión lineal

Capítulo 1

Inferencia univariada

En este capítulo daremos un repaso de algunos de los conceptos fundamentales de la inferencia estadística univariada, incluyendo la estimación de la media utilizando intervalos de confianza y las pruebas de hipótesis para la misma. Estos conceptos son fundamentales para entender los métodos multivariados que se presentarán en los capítulos posteriores. Pero antes de empezar, cargaremos las librerías que necesitaremos para este capítulo y estableceremos algunas configuraciones generales.

```
# Cargamos las librerías necesarias
library(tidyverse)
library(krulRutils)
library(latex2exp)
library(patchwork)

# Fijamos la semilla para reproducibilidad
set.seed(123)

# Evitamos notación científica
options(scipen = 999)
```

1.1. Estimación de la media por intervalos

Supongamos que tenemos una variable aleatoria Y_0 que sigue una distribución normal con media μ y varianza σ^2 , es decir,

$$Y_0 \sim \mathcal{N}(\mu, \sigma^2)$$

Supongamos además que queremos recolectar una muestra de tamaño n de esta variable aleatoria, que utilizaremos para estimar el valor de la media μ . Utilizaremos las variables aleatorias $Y_1, Y_2, \dots, Y_n$ para denotar los posibles valores de esta muestra. Notemos que estas variables aleatorias son independientes e idénticamente distribuidas (i.i.d.) y que cada una de ellas sigue la misma distribución normal que Y_0 , es decir,

$$Y_i \sim \mathcal{N}(\mu, \sigma^2) \quad i = 1, 2, \dots, n$$

I. Análisis de regresión lineal

Para estimar el valor de μ , utilizaremos la media muestral, definida como

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$$

Notemos que la media muestral $\bar{Y}$ es una variable aleatoria que también sigue una distribución normal, con media μ y varianza σ^2/n , es decir,

$$\bar{Y} \sim \mathcal{N}(\mu, \sigma^2/n)$$

En particular,

$$E[\bar{Y}] = \mu$$

En otras palabras, la media muestral es un estimador insesgado de la media poblacional μ . Además, el que la varianza de la media muestral sea σ^2/n significa que a medida que aumentamos el tamaño de la muestra n , la varianza de la media muestral disminuye y, por lo tanto, la media muestral se vuelve un estimador más preciso del parámetro μ . Aún más, si definimos la variable aleatoria

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$$

entonces S^2 es un estimador insesgado de la varianza poblacional σ^2 , es decir,

$$E[S^2] = \sigma^2$$

Notemos que la variable aleatoria S^2 sigue una distribución chi-cuadrada con $n-1$ grados de libertad, es decir,

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$$

Además, las variables aleatorias $\bar{Y}$ y S^2 son independientes, por lo que la variable aleatoria

$$T = \frac{\bar{Y} - \mu}{S/\sqrt{n}} \sim t_{n-1}$$

donde t_{n-1} denota la distribución t de Student con $n-1$ grados de libertad. Notemos que la variable aleatoria T es una función de la media muestral $\bar{Y}$, la varianza muestral S^2 y el tamaño de la muestra n . Notemos además que su distribución asociada no depende del valor de μ ni de σ^2 . Sea ahora $t_{\alpha/2, n-1}$ el cuantil de orden $1 - \alpha/2$ de la distribución t de Student con $n-1$ grados de libertad. En otras palabras, $t_{\alpha/2, n-1}$ es el valor tal que

$$P(-t_{\alpha/2, n-1} < T < t_{\alpha/2, n-1}) = 1 - \alpha$$

Reescribiendo esta desigualdad en términos de μ , obtenemos

$$P\left(\bar{Y} - t_{\alpha/2, n-1} \frac{S}{\sqrt{n}} < \mu < \bar{Y} + t_{\alpha/2, n-1} \frac{S}{\sqrt{n}}\right) = 1 - \alpha$$

Supongamos ahora que realizamos el muestreo correspondiente y que obtenemos $y_1, y_2, \dots, y_n$ como los valores de la muestra. Podemos entonces calcular la media muestral $\bar{y}$ así como la varianza muestral s^2 , y podemos utilizar estos valores para construir el intervalo de confianza

$$\left(\bar{y} - t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}, \bar{y} + t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}\right)$$

1. Inferencia univariada

para μ con un nivel de confianza del $100(1 - \alpha) \%$. Notemos que esto significa que si repitiéramos este procedimiento muchas veces, entonces esperaríamos que alrededor del $100(1 - \alpha) \%$ de los intervalos de confianza obtenidos de esta forma contendrían el valor verdadero de μ .

De manera más explícita, supongamos que Y_0 tiene una distribución normal estándar, es decir, $\mu = 0$ y $\sigma^2 = 1$. Supongamos además que queremos considerar muestras de tamaño $n = 10$. Notemos que en este caso tenemos que

$$\bar{Y} = \frac{1}{10} \sum_{i=1}^{10} Y_i \sim \mathcal{N}(0, 1/10)$$

Para comparar las variables aleatorias Y_0 y $\bar{Y}$, tomaremos una muestra de tamaño 50 para Y_0 y tomaremos una colección de 50 muestras de tamaño 10 para $\bar{Y}$.

```
# Fijamos los parámetros de la distribución normal y
# el tamaño de la muestra
mu <- 0
sigma <- 1
n <- 10

# Creamos los datos para las densidades
x_data <- seq(-2.5, 2.5, length.out = 1000)
y0_density_data <- dnorm(x_data, mean = mu, sd = sigma)
ybar_density_data <- dnorm(x_data, mean = mu, sd = sigma / sqrt(n))

# Generamos la muestra de tamaño 50 para Y0
y0_data <- rnorm(50, mean = mu, sd = sigma)

# Generamos las 50 muestras de tamaño n para Ybar
y_samples_tbl <- tibble(
  y = rnorm(50 * n, mean = mu, sd = sigma),
  sample = rep(1:50, each = n)
)

# Creamos los tibbles para la densidad de Y0
y0_density_tbl <- tibble(
  x = x_data,
  y = y0_density_data
)

# Creamos el tibble para la densidad de Ybar
ybar_density_tbl <- tibble(
  x = x_data,
  y = ybar_density_data
)

# Creamos el tibble para la muestra de Y0
y0_sample_tbl <- tibble(
```

```
y0 = y0_data
)

# Creamos el tibble para la muestra de Ybar
ybar_sample_tbl <- y_samples_tbl |>
  group_by(sample) |>
  summarise(
    ybar = mean(y),
    s = sd(y)
  )

# Generamos el gráfico de densidad para Y0
y0_density_plot <- y0_density_tbl |>
  ggplot(aes(x = x, y = y)) +
  geom_line(
    color = c_pal("C blue"),
    linewidth = 1
  ) +
  coord_cartesian(xlim = c(-2.5, 2.5)) +
  labs(
    title = TeX("Densidad de  $Y_0$ "),
    x = TeX(" $Y_0$ "),
    y = "Densidad"
  ) +
  theme_krul()

# Generamos el gráfico de densidad para Ybar
ybar_density_plot <- ybar_density_tbl |>
  ggplot(aes(x = x, y = y)) +
  geom_line(
    color = c_pal("C blue"),
    linewidth = 1
  ) +
  coord_cartesian(xlim = c(-2.5, 2.5)) +
  labs(
    title = TeX("Densidad de  $\bar{Y}$ "),
    x = TeX(" $\bar{Y}$ "),
    y = "Densidad"
  ) +
  theme_krul()

# Generamos el histograma para la muestra de Y0
y0_hist <- y0_sample_tbl |>
  ggplot(aes(x = y0)) +
  geom_histogram(
```

1. Inferencia univariada

```
    bins = 10,
    color = "black",
    fill = c_pal("C blue"),
    alpha = 0.7
  ) +
  coord_cartesian(xlim = c(-2.5, 2.5)) +
  labs(
    title = TeX("Muestra de tamaño 50 de  $Y_{0}$ "),
    x = TeX(" $Y_{0}$ "),
    y = "Frecuencia"
  ) +
  theme_krul()

# Generamos el histograma para la muestra de Ybar
ybar_hist <- ybar_sample_tbl |>
  ggplot(aes(x = ybar)) +
  geom_histogram(
    bins = 10,
    color = "black",
    fill = c_pal("C blue"),
    alpha = 0.7
  ) +
  coord_cartesian(xlim = c(-2.5, 2.5)) +
  labs(
    title = TeX("Muestra de tamaño 50 de  $\bar{Y}$ "),
    x = TeX(" $\bar{Y}$ "),
    y = "Frecuencia"
  ) +
  theme_krul()

# Combinamos los gráficos de densidad y
# los histogramas en un solo gráfico
# utilizando la librería patchwork
combined_y_plot <- ((y0_density_plot | y0_hist) /
  (ybar_density_plot | ybar_hist)) +
  plot_annotation(
    title = "Comparación de la variable aleatoria original y la media muestral",
    theme = theme(
      plot.title = element_text(
        size = 24,
        face = "bold"
      )
    )
  )
)
```

```
# Mostramos el gráfico combinado
combined_y_plot
```

Comparación de la variable aleatoria original y la media muestral




Figura 1.1: Comparación entre la variable aleatoria original y la media muestral, utilizando una muestra de tamaño 50 para cada una de ellas.

Tomaremos ahora un valor de $\alpha = 0.2$. Entonces el valor del cuantil de orden $1 - \alpha/2 = 0.9$ de la distribución t de Student con $n - 1 = 9$ grados de libertad es

$$t_{\alpha/2, n-1} = t_{0.1, 9} \approx 1.383$$

En otras palabras,

$$P(-t_{\alpha/2, n-1} < T < t_{\alpha/2, n-1}) = 1 - \alpha = 0.8$$

```
# Creamos los datos para la densidad de la distribución t de Student
x_data <- seq(-4, 4, length.out = 1000)
t_density_data <- dt(x_data, df = n - 1)

# Creamos el tibble para la densidad de la distribución t de Student
t_density_tbl <- tibble(
  x = x_data,
  y = t_density_data
)

# Calculamos el valor crítico t_alpha para
# alpha = 0.2 y n - 1 = 9 grados de libertad
t_alpha <- qt(0.1, df = n - 1, lower.tail = FALSE)
```

1. Inferencia univariada

```
# Creamos un tibble para la región crítica de la distribución t de Student
t_middle_tbl <- t_density_tbl |>
  filter(x >= -t_alpha, x <= t_alpha)

# Generamos el gráfico de densidad para la distribución
# t de Student con los valores críticos
t_density_plot <- t_density_tbl |>
  ggplot(aes(x = x, y = y)) +
  geom_line(
    color = c_pal("C blue"),
    linewidth = 1
  ) +
  geom_area(
    data = t_middle_tbl,
    fill = c_pal("C blue"),
    alpha = 0.7
  ) +
  geom_vline(
    xintercept = c(-t_alpha, t_alpha),
    color = c_pal("C green"),
    linetype = "solid",
    linewidth = 1
  ) +
  annotate(
    "text",
    x = t_alpha + 0.5,
    y = 0.2,
    label = TeX(paste0("$T = ", round(t_alpha, 4), "$")),
    color = c_pal("C green"),
    size = 5
  ) +
  annotate(
    "text",
    x = -t_alpha - 0.5,
    y = 0.2,
    label = TeX(paste0("$T = ", round(-t_alpha, 4), "$")),
    color = c_pal("C green"),
    size = 5
  ) +
  coord_cartesian(xlim = c(-4, 4)) +
  labs(
    title = TeX("Densidad de la distribución $t$ de Student"),
    x = TeX("$T$"),
    y = "Densidad"
  ) +
```

```
theme_krul()

# Mostramos el gráfico de densidad de la distribución t de Student
t_density_plot
```




Figura 1.2: Densidad de la distribución t de Student con $n - 1 = 9$ grados de libertad, con los valores críticos para $\alpha = 0.2$. Notemos que el área sombreada contiene el 80 % de la densidad de la distribución t de Student.

Usando este valor crítico, podemos construir los intervalos de confianza para μ con un nivel de confianza del 80 % asociados a cada una de las 50 muestras de tamaño 10 que tomamos para $\bar{Y}$. La siguiente figura ilustra estos intervalos de confianza, donde la línea horizontal azul representa el valor verdadero de $\mu = 0$.

```
# Calculamos los intervalos de confianza para cada una de las 50 muestras
confidence_intervals_tbl <- y_samples_tbl |>
  group_by(sample) |>
  summarise(
    ybar = mean(y),
    s = sd(y)
  ) |>
  mutate(
    lower = ybar - t_alpha * s / sqrt(n),
    upper = ybar + t_alpha * s / sqrt(n)
  )

# Graficamos los intervalos de confianza
```

1. Inferencia univariada

```
confidence_intervals_plot <- confidence_intervals_tbl |>
  ggplot(aes(x = sample, y = ybar)) +
  geom_errorbar(
    aes(ymin = lower, ymax = upper),
    width = 0.5,
    color = c_pal("C green")
  ) +
  geom_point(
    color = c_pal("C red"),
    size = 2
  ) +
  geom_hline(yintercept = mu, color = c_pal("C blue"), linewidth = 1) +
  labs(
    title = TeX(
      "Intervalos de confianza del 80\\% para $\\mu$"
    ),
    x = "Muestra",
    y = TeX("$Y_{0}$")
  ) +
  theme_krul()

# Mostramos el gráfico de intervalos de confianza
confidence_intervals_plot
```




Figura 1.3: Intervalos de confianza para μ con un nivel de confianza del 80 % asociados a cada una de las 50 muestras de tamaño 10 construidas para $\bar{Y}$. La línea horizontal azul representa el valor verdadero de $\mu = 0$.

1.2. Pruebas de hipótesis para la media

Hasta el momento hemos considerado el parámetro μ como un valor desconocido, pero fijo, que buscamos estimar a partir de una muestra. Sin embargo, en muchas ocasiones tenemos un valor específico de μ , y queremos determinar si los datos que hemos recolectado son consistentes con este valor. De manera más concreta, en el contexto de pruebas de hipótesis para la media empezamos suponiendo que tenemos un valor específico de μ , que denotaremos como μ_0 . A partir de este valor, formulamos dos hipótesis estadísticas: la hipótesis nula H_0 y la hipótesis alternativa H_1 . La hipótesis nula H_0 establece que el valor verdadero de μ es igual a μ_0 , mientras que la hipótesis alternativa H_1 establece que el valor verdadero de μ es diferente de μ_0 . En otras palabras, tenemos

$$H_0 : \mu = \mu_0 \quad \text{vs.} \quad H_1 : \mu \neq \mu_0$$

Capítulo 2

Regresión lineal simple

Empezamos por cargar las librerías necesarias para este cuaderno:

```
library(tidyverse)
library(krulRutils)
library(latex2exp)
library(patchwork)
set.seed(123)
```

2.1. El modelo de regresión lineal simple

En un *modelo de regresión simple*, suponemos que tenemos una *variable independiente* X_0 (también conocida como *variable explicativa* o *predictora*), y una *variable dependiente* Y_0 (también conocida como *variable de respuesta*). Suponemos además que estas variables satisfacen una relación de la forma:

$$Y_0 = f_0(X_0) + \epsilon_0$$

donde f_0 es una función desconocida que describe la relación entre ambas variables, y ϵ_0 es una variable aleatoria que representa el *error* o *ruido* en la relación entre X_0 e Y_0 . Uno de los objetivos del *aprendizaje estadístico* (también conocido como *aprendizaje automático* o *machine learning*), es tratar de aproximar la función f_0 a partir de un conjunto de datos

$$((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$$

dado. De manera más precisa, consideremos vectores aleatorios

$$X = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{bmatrix}, \quad Y = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}$$

que representan los posibles valores de las observaciones independientes y dependientes, respectivamente, en una muestra dada. En este contexto, un *método de aprendizaje* consiste de una función

I. Análisis de regresión lineal

$\hat{F}$, que depende de los vectores aleatorios X e Y , y que cuando se evalúa en los datos observados produce una función $\hat{f}$ que aproxima a la función desconocida f_0 .

Nota 2.1.1. En muchos modelos de aprendizaje estadístico es común tomar el vector $X = x$ como fijo, en cuyo caso la función $\hat{F}$ depende únicamente del vector aleatorio Y .

Para hacer estas ideas un poco más concretas, consideremos el caso particular en el que la función desconocida f_0 es una función lineal, es decir,

$$f_0(X_0) = b_0 + b_1 X_0$$

y supondremos además que $\epsilon_0 \sim \mathcal{N}(0, \sigma^2)$ es una variable aleatoria con distribución normal de media 0 y varianza σ^2 . Este contexto se conoce como el *modelo de regresión lineal simple* y es uno de los modelos más utilizados en aprendizaje estadístico. Notemos que en este caso nuestro objetivo es encontrar una expresión que nos permita aproximar los parámetros desconocidos b_0 y b_1 en términos de los datos observados. Para ello consideraremos las expresiones que obtuvimos en la sección anterior para los coeficientes de la recta de mejor ajuste por mínimos cuadrados, pero utilizando ahora el vector aleatorio Y en lugar del vector de observaciones y . En otras palabras, definiremos

$$\Phi = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}$$

y consideraremos las matrices $D^2 = (\Phi^T \Phi)^{-1}$, $A = D^2 \Phi^T$ y $H = \Phi A$. Entonces podemos definir el *vector aleatorio de estimadores de mínimos cuadrados* como:

$$\hat{B} = AY$$

Notemos que, a diferencia de la sección anterior, en este caso $\hat{B}$ no es un vector de valores fijos, sino que es un vector aleatorio que depende linealmente del vector aleatorio Y . Además, de las propiedades de la distribución normal multivariada, sabemos que

$$\hat{B} \sim \mathcal{N}(b, \sigma^2 D^2)$$

donde

$$b = \begin{bmatrix} b_0 \\ b_1 \end{bmatrix}$$

es el vector de parámetros desconocidos. Notemos que, en particular, el vector aleatorio $\hat{B}$ es un estimador insesgado del vector de parámetros b , es decir, $E[\hat{B}] = b$. Notemos además que si evaluamos el vector aleatorio $\hat{B}$ en los datos observados $Y = y$, obtenemos el vector de coeficientes $\hat{\beta}$ de la recta de mejor ajuste por mínimos cuadrados que obtuvimos en la sección anterior. Una vez hechas estas observaciones, nuestro siguiente objetivo será construir los intervalos de confianza para los parámetros b_0 y b_1 .

2. Regresión lineal simple

2.2. Estimación de parámetros por intervalos de confianza

Empecemos por definir las cantidades

$$d_0^2 = D_{11}^2 = \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}$$

$$d_1^2 = D_{22}^2 = \frac{1}{S_{xx}}$$

donde

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$$

tal y como lo habíamos definido en la sección anterior. Entonces

$$\hat{B}_0 \sim \mathcal{N}(b_0, \sigma^2 d_0^2)$$

$$\hat{B}_1 \sim \mathcal{N}(b_1, \sigma^2 d_1^2)$$

Consideremos ahora la variable aleatoria

$$\hat{S}^2 = \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

donde

$$\hat{Y} = \begin{bmatrix} \hat{Y}_1 \\ \hat{Y}_2 \\ \vdots \\ \hat{Y}_n \end{bmatrix} = HY$$

es el *vector aleatorio de predicciones por mínimos cuadrados*. Entonces tenemos que

$$\frac{(n-2)\hat{S}^2}{\sigma^2} \sim \chi_{n-2}^2$$

y, además, la variable aleatoria $\hat{S}^2$ es independiente de las variables aleatorias $\hat{B}_0$ y $\hat{B}_1$. Por lo tanto, podemos construir las nuevas variables aleatorias

$$T_0 = \frac{\hat{B}_0 - b_0}{\hat{S}d_0} \sim t_{n-2}$$

$$T_1 = \frac{\hat{B}_1 - b_1}{\hat{S}d_1} \sim t_{n-2}$$

donde t_{n-2} denota la distribución t de Student con $n-2$ grados de libertad. Con esta información, podemos construir ahora los intervalos de confianza para los parámetros b_0 y b_1 , tal y como nos lo habíamos propuesto. Empecemos por fijar un nivel de significancia α y sea $t_{\alpha/2, n-2}$ el cuantil superior de orden $\alpha/2$ de la distribución t de Student correspondiente. Entonces, si tomamos $\hat{s}$ como

el valor de la variable aleatoria $\hat{S}$ evaluada en el vector de datos observados $Y = y$, tenemos que los intervalos de confianza buscados son

$$(\hat{\beta}_0 - t_{\alpha/2, n-2} \hat{s} d_0, \hat{\beta}_0 + t_{\alpha/2, n-2} \hat{s} d_0)$$

para b_0 , y

$$(\hat{\beta}_1 - t_{\alpha/2, n-2} \hat{s} d_1, \hat{\beta}_1 + t_{\alpha/2, n-2} \hat{s} d_1)$$

para b_1 .

2.3. Bandas de confianza y de predicción

Una vez obtenidos los intervalos de confianza para los parámetros b_0 y b_1 , nos gustaría obtener ahora los intervalos de confianza para los posibles valores de la variable dependiente Y_0 en un valor específico de la variable independiente $X_0 = x_0$. Para esto empezaremos por considerar la matriz de diseño en el punto x_0 :

$$\Phi_0 = \begin{bmatrix} 1 & x_0 \end{bmatrix}$$

y definiremos el vector aleatorio

$$\hat{Y}_0 = \Phi_0 \hat{B} = \hat{B}_0 + \hat{B}_1 x_0$$

Notemos que este vector aleatorio depende solamente de las variables $\hat{B}_0$ y $\hat{B}_1$ (las cuales, a su vez, dependen solamente de las variables $Y_1, Y_2, \dots, Y_n$), y es independiente de la variable aleatoria Y_0 . Usando nuevamente las propiedades de la distribución normal multivariada, podemos ver que

$$\hat{Y}_0 \sim \mathcal{N}(\Phi_0 b, \sigma^2 d_c^2)$$

donde

$$d_c^2 = \Phi_0 D^2 \Phi_0^T = \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}$$

Finalmente, como $\hat{Y}_0$ es independiente de la variable aleatoria $\hat{S}^2$, podemos construir la variable aleatoria

$$T_c = \frac{\hat{Y}_0 - \Phi_0 b}{\hat{S} d_c} \sim t_{n-2}$$

Se sigue que para construir un intervalo de confianza para el valor esperado de la variable dependiente Y_0 en el punto $X_0 = x_0$, basta con tomar el intervalo

$$(\hat{y}_0 - t_{\alpha/2, n-2} \hat{s} d_c, \hat{y}_0 + t_{\alpha/2, n-2} \hat{s} d_c)$$

donde $\hat{y}_0$ es el valor de la variable aleatoria $\hat{Y}_0$ evaluada en los datos observados $Y = y$. Notemos que este intervalo depende del punto $X_0 = x_0$ que hayamos elegido. De manera más general, podemos considerar el conjunto de todos los intervalos de confianza para todos los posibles valores de x_0 , el cual se conoce como la *banda de confianza* del modelo de regresión lineal simple.

Para terminar, notemos que como Y_0 es independiente de $\hat{Y}_0$, tenemos que

$$Y_0 - \hat{Y}_0 \sim \mathcal{N}(0, \sigma^2 d_p^2)$$

2. Regresión lineal simple

donde

$$d_p^2 = 1 + d_c^2 = 1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}$$

Usando nuevamente la variable aleatoria $\hat{S}^2$, podemos definir ahora

$$T_p = \frac{Y_0 - \hat{Y}_0}{\hat{S}d_p} \sim t_{n-2}$$

y, de manera similar a como lo hicimos antes, podemos construir un *intervalo de predicción* para el valor de la variable dependiente Y_0 en el punto $X_0 = x_0$ como

$$(\hat{y}_0 - t_{\alpha/2, n-2} \hat{S}d_p, \hat{y}_0 + t_{\alpha/2, n-2} \hat{S}d_p)$$

Nuevamente, el conjunto de todos estos intervalos de predicción para todos los posibles valores de x_0 se conoce como la *banda de predicción* del modelo de regresión lineal simple.

2.4. Ejemplo de construcción de bandas de confianza y de predicción

Supongamos que tenemos el vector

$$x = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$$

Para generar el vector de las observaciones dependientes, consideraremos un modelo de la forma

$$Y_0 = b_0 + b_1 X_0 + \epsilon_0$$

con $b_0 = 0$, $b_1 = 1$ y suponiendo que $\epsilon_0 \sim \mathcal{N}(\mu, \sigma^2)$ es una distribución normal con parámetros $\mu = 0$ y $\sigma = 0.3$ Redondeando a dos decimales, el vector resultante es:

```
library(tidyverse)
set.seed(123)
x_data <- c(1, 2, 3)
epsilon_data <- rnorm(3, mean = 0, sd = 0.3)
y_data <- x_data + epsilon_data
sample_data_tbl <- tibble(
  x = x_data,
  y = y_data
)

fmt <- function(x, digits = 2) {
  format(round(unname(x), digits), nsmall = digits)
}

alpha <- 0.05
phi <- cbind(1, x_data)
```

```
d2_mat <- solve(t(phi) %*% phi)
a_mat <- d2_mat %*% t(phi)
h_mat <- phi %*% a_mat
x_bar <- mean(x_data)
s_xx <- sum((x_data - x_bar)^2)

model <- lm(y ~ x, data = sample_data_tbl)
beta_hat <- coef(model)
y_hat <- fitted(model)
sse <- deviance(model)
df_model <- length(x_data) - length(beta_hat)
s_hat <- sqrt(sse / df_model)
t_stats <- c(
  beta_hat[1] / (s_hat * sqrt(d2_mat[1, 1])),
  (beta_hat[2] - 1) / (s_hat * sqrt(d2_mat[2, 2]))
)
p_values <- 2 * pt(abs(t_stats), df = df_model, lower.tail = FALSE)
t_alpha <- qt(1 - alpha / 2, df = df_model)
ci_beta <- confint(model, level = 1 - alpha)
band_scale <- s_hat * t_alpha / sqrt(6)
round(y_data, 2)
```

```
[1] 0.83 1.93 3.47
```

Así que para este ejemplo, consideraremos el vector de observaciones dependientes

$$x = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \quad y = \begin{bmatrix} 0.83 \\ 1.93 \\ 3.47 \end{bmatrix}$$

Nos gustaría encontrar la recta que mejor se ajusta a estos datos de acuerdo al método de mínimos cuadrados y calcular sus bandas de confianza y predicción. Para esto empezaremos por considerar la matriz de diseño

$$\Phi = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}$$

Necesitamos ahora calcular la matriz de coeficientes dada por $D^2 = (\Phi^T \Phi)^{-1}$, empezaremos por calcular

$$\Phi^T \Phi = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} = \begin{bmatrix} 3 & 6 \\ 6 & 14 \end{bmatrix}$$

Su inversa está entonces dada por:

$$D^2 = (\Phi^T \Phi)^{-1} = \frac{1}{3(14) - 6(6)} \begin{bmatrix} 14 & -6 \\ -6 & 3 \end{bmatrix} = \frac{1}{6} \begin{bmatrix} 14 & -6 \\ -6 & 3 \end{bmatrix}$$

2. Regresión lineal simple

En particular,

$$d_0^2 = \frac{14}{6} = \frac{7}{3} \quad d_1^2 = \frac{3}{6} = \frac{1}{2}$$

Calculamos ahora la matriz de estimadores de mínimos cuadrados

$$A = D^2 \Phi^T = \frac{1}{6} \begin{bmatrix} 14 & -6 \\ -6 & 3 \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{bmatrix} = \frac{1}{6} \begin{bmatrix} 8 & 2 & -4 \\ -3 & 0 & 3 \end{bmatrix}$$

y la matriz sombrero

$$H = \Phi A = \frac{1}{6} \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 8 & 2 & -4 \\ -3 & 0 & 3 \end{bmatrix} = \frac{1}{6} \begin{bmatrix} 5 & 2 & -1 \\ 2 & 2 & 2 \\ -1 & 2 & 5 \end{bmatrix}$$

Con estas matrices podemos calcular ahora los estimadores puntuales

$$\hat{\beta} = Ay = \frac{1}{6} \begin{bmatrix} 8 & 2 & -4 \\ -3 & 0 & 3 \end{bmatrix} \begin{bmatrix} 0.83 \\ 1.93 \\ 3.47 \end{bmatrix} = \begin{bmatrix} -0.56 \\ 1.32 \end{bmatrix}$$

Además de

$$\hat{y} = Hy = \frac{1}{6} \begin{bmatrix} 5 & 2 & -1 \\ 2 & 2 & 2 \\ -1 & 2 & 5 \end{bmatrix} \begin{bmatrix} 0.83 \\ 1.93 \\ 3.47 \end{bmatrix} = \begin{bmatrix} 0.76 \\ 2.08 \\ 3.39 \end{bmatrix}$$

Finalmente, podemos calcular

$$\text{SSE} = \|y - \hat{y}\|^2 = 0.032$$

Si comparamos ahora estos resultados con los obtenidos por R:

```
beta_hat
```

```
(Intercept)      x
-0.5589497    1.3178776
```

```
y_hat
```

```
      1      2      3
0.7589279 2.0768055 3.3946831
```

```
sse
```

```
[1] 0.03191217
```

podemos notar que (salvo errores de redondeo) los resultados son idénticos.

Ahora nos gustaría poder calcular los intervalos de confianza para $\hat{\beta}_0$ y $\hat{\beta}_1$. Para poder lograr este objetivo, necesitamos convertir los cálculos que hemos hecho hasta ahora de manera puntual en

I. Análisis de regresión lineal

cálculos que involucren variables aleatorias. Empezamos por introducir la variable de las observaciones dependientes

$$Y = \begin{bmatrix} Y_1 \\ Y_2 \\ Y_3 \end{bmatrix}$$

Construimos ahora las variables

$$\hat{B} = \begin{bmatrix} \hat{B}_0 \\ \hat{B}_1 \end{bmatrix} = AY = \frac{1}{6} \begin{bmatrix} 8Y_1 + 2Y_2 - 4Y_3 \\ -3Y_1 + 3Y_3 \end{bmatrix}$$

Sabemos que esta variable aleatoria tiene distribución

$$\hat{B} \sim \mathcal{N}(b, \sigma^2 D^2)$$

donde

$$b = \begin{bmatrix} b_0 \\ b_1 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

En particular,

$$\hat{B}_0 \sim \mathcal{N}(b_0, \sigma^2 d_0^2) = \mathcal{N}(0, 0.21)$$

y

$$\hat{B}_1 \sim \mathcal{N}(b_1, \sigma^2 d_1^2) = \mathcal{N}(1, 0.045)$$

Para continuar con nuestros cálculos, necesitamos ahora introducir el vector aleatorio

$$\hat{Y} = HY = \frac{1}{6} \begin{bmatrix} 5 & 2 & -1 \\ 2 & 2 & 2 \\ -1 & 2 & 5 \end{bmatrix} \begin{bmatrix} Y_1 \\ Y_2 \\ Y_3 \end{bmatrix} = \frac{1}{6} \begin{bmatrix} 5Y_1 + 2Y_2 - Y_3 \\ 2Y_1 + 2Y_2 + 2Y_3 \\ -Y_1 + 2Y_2 + 5Y_3 \end{bmatrix}$$

el cual podemos utilizar para construir el siguiente estimador para la varianza σ^2

$$\hat{S}^2 = \frac{1}{n-2} \|Y - \hat{Y}\|^2 = \|Y - \hat{Y}\|^2$$

en donde estamos utilizando que nuestros vectores tienen dimensión $n = 3$ y por tanto tenemos solamente un grado de libertad. Notemos que cuando $Y = y$ es el vector de valores observados esta variable aleatoria toma el valor

2. Regresión lineal simple

$$\hat{s}^2 = \text{SSE} = 0.032$$

En particular,

$$\hat{s} = 0.18$$

Por tanto, podemos utilizar este valor para calcular los estadísticos

$$T_0 = \frac{\hat{B}_0 - b_0}{\hat{S}d_0} \sim t_{n-2} = t_1$$

y

$$T_1 = \frac{\hat{B}_1 - b_1}{\hat{S}d_1} \sim t_{n-2} = t_1$$

los valores obtenidos son:

$$t_0 = -2.05$$

y

$$t_1 = 2.52$$

Los valores p asociados a estos estadísticos son:

$$p_{t_0} = 0.29 \quad p_{t_1} = 0.24$$

Para construir los intervalos de confianza, tomaremos $\alpha = 0.05$ y calculamos el estadístico t asociado a este nivel de significancia para una prueba de dos colas:

$$t_{\alpha/2,1} = 12.71$$

Se sigue que el intervalo de confianza para b_0 está dado por

$$(\hat{\beta}_0 - t_{\alpha/2,1} d_0 \hat{s}, \hat{\beta}_0 + t_{\alpha/2,1} d_0 \hat{s}) = (-4.03, 2.91)$$

Mientras que el intervalo de confianza para b_1 está dado por

$$(\hat{\beta}_1 - t_{\alpha/2,1} d_1 \hat{s}, \hat{\beta}_1 + t_{\alpha/2,1} d_1 \hat{s}) = (-0.29, 2.92)$$

I. Análisis de regresión lineal

Para construir ahora las bandas de confianza y predicción, notemos que para nuestro vector x tenemos que

$$\bar{x} = 2 \quad s_{xx} = 2$$

Como

$$\hat{Y}_0 \sim \mathcal{N}(b_0 + b_1 X_0, \sigma^2 d_c^2)$$

donde

$$d_c^2 = \frac{1}{n} + \frac{(X_0 - \bar{x})^2}{s_{xx}} = \frac{1}{3} + \frac{(X_0 - 2)^2}{2}$$

Se sigue que el estadístico

$$T_c = \frac{\hat{Y}_0 - (b_0 + b_1 X_0)}{\hat{s} d_c} \sim t_{n-2} = t_1$$

En particular, el intervalo de confianza para la media en un punto dado $X_0 = x_0$ está dado por

$$(\hat{\beta}_0 + \hat{\beta}_1 x_0 - \hat{s} t_{\alpha/2,1} d_c, \hat{\beta}_0 + \hat{\beta}_1 x_0 + \hat{s} t_{\alpha/2,1} d_c)$$

que en nuestro caso corresponde al intervalo

$$(-0.56 + 1.32x_0 - 0.93 \sqrt{2 + 3(x_0 - 2)^2}, -0.56 + 1.32x_0 + 0.93 \sqrt{2 + 3(x_0 - 2)^2})$$

Similarmente, el intervalo de predicción está dado por

$$(-0.56 + 1.32x_0 - 0.93 \sqrt{8 + 3(x_0 - 2)^2}, -0.56 + 1.32x_0 + 0.93 \sqrt{8 + 3(x_0 - 2)^2})$$

```
# Creamos un vector de valores de $x$ para graficar
# las bandas de confianza y predicción
x_band <- seq(-3, 7, length.out = 200)

# Creamos un nuevo punto $(x_0, y_0)$ para graficar
x_0 <- runif(1, -3, 7)
epsilon_0 <- rnorm(1, mean = 0, sd = 0.3)
y_0 <- x_0 + epsilon_0

# Creamos un tibble con el nuevo punto
new_data_tbl <- tibble(x = x_0, y = y_0)
```

2. Regresión lineal simple

```
# Creamos la función para calcular el límite superior
# de la banda de confianza
confidence_upper <- function(x_0) {
  beta_hat[1] + beta_hat[2] * x_0 +
    band_scale * sqrt(2 + 3 * (x_0 - 2)^2)
}

# Creamos la función para calcular el límite inferior
# de la banda de confianza
confidence_lower <- function(x_0) {
  beta_hat[1] + beta_hat[2] * x_0 -
    band_scale * sqrt(2 + 3 * (x_0 - 2)^2)
}

# Creamos la función para calcular el límite superior
# de la banda de predicción
prediction_upper <- function(x_0) {
  beta_hat[1] + beta_hat[2] * x_0 +
    band_scale * sqrt(8 + 3 * (x_0 - 2)^2)
}

# Creamos la función para calcular el límite inferior
# de la banda de predicción
prediction_lower <- function(x_0) {
  beta_hat[1] + beta_hat[2] * x_0 -
    band_scale * sqrt(8 + 3 * (x_0 - 2)^2)
}

# Creamos la función para calcular la recta ajustada
adjusted_line <- function(x_0) {
  beta_hat[1] + beta_hat[2] * x_0
}

# Calculamos los valores de las bandas de confianza y predicción
y_prediction_upper <- prediction_upper(x_band)
y_prediction_lower <- prediction_lower(x_band)
y_confidence_upper <- confidence_upper(x_band)
y_confidence_lower <- confidence_lower(x_band)
y_adjusted_line <- adjusted_line(x_band)

# Creamos un tibble con los valores de las
# bandas de confianza y predicción
lines_tbl <- bind_rows(
  tibble(
    x = x_band, y = y_prediction_upper,
```

```
    type = "Banda de predicción", curve = "pred_sup"
  ),
  tibble(
    x = x_band, y = y_prediction_lower,
    type = "Banda de predicción", curve = "pred_inf"
  ),
  tibble(
    x = x_band, y = y_confidence_upper,
    type = "Banda de confianza", curve = "conf_sup"
  ),
  tibble(
    x = x_band, y = y_confidence_lower,
    type = "Banda de confianza", curve = "conf_inf"
  ),
  tibble(
    x = x_band, y = y_adjusted_line,
    type = "Recta ajustada", curve = "ajustada"
  ),
  tibble(
    x = x_band, y = x_band,
    type = "Recta esperada", curve = "esperada"
  )
)

# Creamos la gráfica con las bandas de confianza y predicción
sample_data_plot <- sample_data_tbl |>
  ggplot(aes(x = x, y = y)) +
  geom_line(
    data = lines_tbl,
    aes(x = x, y = y, color = type, group = curve),
    linewidth = 1
  ) +
  scale_color_manual(
    values = c(
      "Banda de predicción" = unname(c_pal("C green")),
      "Banda de confianza" = unname(c_pal("C magenta")),
      "Recta ajustada" = unname(c_pal("C orange")),
      "Recta esperada" = unname(c_pal("C blue"))
    )
  ) +
  geom_point(color = c_pal("C red"), size = 1.2, alpha = 1) +
  geom_point(
    data = new_data_tbl,
    aes(x = x, y = y),
    color = c_pal("C red"),
```

2. Regresión lineal simple

```
size = 2,  
alpha = 1  
) +  
labs(  
  title = "Gráfica con recta ajustada por mínimos cuadrados",  
  x = "x",  
  y = "y",  
  color = "Elementos de la gráfica"  
) +  
theme_krul()  
  
# Mostramos la gráfica  
sample_data_plot
```




Figura 2.1: Regresión lineal simple con bandas de confianza y de predicción. La línea azul representa la recta esperada, la línea café representa la recta ajustada por mínimos cuadrados, la banda magenta representa la banda de confianza y la banda verde representa la banda de predicción. El punto rojo más grande representa una nueva observación (x_0, y_0) .

Capítulo 3

Regresión lineal múltiple

En este capítulo consideraremos el modelo de regresión lineal múltiple, que es una generalización del modelo de regresión lineal simple. En este modelo consideramos un conjunto de variables independientes $X_{01}, X_{02}, \dots, X_{0p}$ y una variable dependiente Y_0 , las cuales satisfacen una relación de la forma:

$$Y_0 = b_0 + b_1 X_{01} + b_2 X_{02} + \dots + b_p X_{0p} + \epsilon_0$$

donde $\epsilon_0 \sim \mathcal{N}(0, \sigma^2)$. Notemos que este modelo depende de los parámetros $b_0, b_1, \dots, b_p$ y σ^2 . En esta capítulo, nos enfocaremos en el estudio de estos parámetros y sus propiedades estadísticas, así como en las diversas maneras de evaluar este modelo.

3.1. Ajuste del modelo de regresión lineal múltiple

Empezaremos por introducir una matriz

$$X = \begin{bmatrix} X_{11} & X_{12} & \dots & X_{1p} \\ X_{21} & X_{22} & \dots & X_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \dots & X_{np} \end{bmatrix}$$

que contiene las variables independientes para n observaciones, y un vector aleatorio

$$Y = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}$$

que contiene las variables dependientes para las mismas n observaciones. En este contexto, la relación entre estas variables se puede expresar de manera matricial como

$$Y = Xb + \epsilon$$

donde

$$b = \begin{bmatrix} b_0 \\ b_1 \\ \vdots \\ b_p \end{bmatrix}$$

es el vector de parámetros y

$$\epsilon = \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{bmatrix}$$

es el vector de errores aleatorios, que asumimos que sigue una distribución normal multivariada

$$\epsilon \sim \mathcal{N}(0, \sigma^2 I_n)$$

Supongamos ahora que tenemos un conjunto de datos observados

$$x = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix}$$

para las variables independientes y

$$y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

para la variable dependiente. De manera similar al caso de regresión lineal simple, podemos definir la matriz de diseño asociada a estos datos como

$$\Phi = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix}$$

Calculamos ahora la matrix de coeficientes

$$D^2 = (\Phi^T \Phi)^{-1}$$

la matriz de estimadores

$$A = D^2 \Phi^T$$

y la matriz sombrero

$$H = \Phi A$$

Con estas matrices podemos calcular ahora los estimadores puntuales

$$\hat{\beta} = Ay$$

3. Regresión lineal múltiple

y los valores ajustados

$$\hat{y} = Hy$$

Para calcular los intervalos de confianza para los parámetros, necesitamos calcular la suma de errores al cuadrado

$$\text{sse} = \|y - \hat{y}\|^2 = \|(I - H)y\|^2$$

Con este valor a la mano, podemos calcular el estimador de la varianza de los errores

$$\hat{\sigma}^2 = \frac{\text{sse}}{n - p - 1}$$

Ahora, dado un nivel de significancia α , podemos calcular los intervalos de confianza para los parámetros $b_0, b_1, \dots, b_p$ como

$$b_j \pm t_{n-p-1, 1-\alpha/2} \sqrt{\hat{\sigma}^2 d_{jj}^2}$$

donde d_{jj}^2 es la entrada (j, j) de la matriz D^2 y $t_{n-p-1, 1-\alpha/2}$ es el cuantil $1 - \alpha/2$ de la distribución t de Student con $n - p - 1$ grados de libertad. Supongamos ahora que tenemos un nuevo vector de datos $x_0 = (x_{01}, x_{02}, \dots, x_{0p})$ para las variables independientes y queremos calcular una banda de confianza para la variable dependiente correspondiente. Para ello, calculamos el valor ajustado

$$\hat{y}_0 = b_0 + b_1 x_{01} + b_2 x_{02} + \dots + b_p x_{0p} = \phi_0 \hat{\beta}$$

donde

$$\phi_0 = \begin{bmatrix} 1 & x_{01} & x_{02} & \dots & x_{0p} \end{bmatrix}$$

es el vector de diseño asociado a los datos x_0 . Con este valor a la mano, podemos calcular la banda de confianza para la predicción de la variable dependiente correspondiente como

$$\hat{y}_0 \pm t_{n-p-1, 1-\alpha/2} \sqrt{\hat{\sigma}^2 (\phi_0 D^2 \phi_0^T)}$$

La banda de predicción para la variable dependiente está dada por la expresión

$$\hat{y}_0 \pm t_{n-p-1, 1-\alpha/2} \sqrt{\hat{\sigma}^2 (1 + \phi_0 D^2 \phi_0^T)}$$

3.2. Evaluación del modelo ajustado

3.2.1. Máxima verosimilitud

Dado un conjunto de datos

$$x = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix} \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

La función de verosimilitud del modelo de regresión lineal es una función que nos da una medida de la consistencia entre los datos dados y los parámetros considerados en el modelo. En nuestro caso, la función de verosimilitud es:

$$L(b_0, b_1, \dots, b_p, \sigma^2 | x, y) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{(y_i - (b_0 + b_1 x_{i1} + \dots + b_p x_{ip}))^2}{2\sigma^2} \right)$$

I. Análisis de regresión lineal

que corresponde, simplemente, a la función de densidad del modelo considerado con los parámetros indicados y los datos observados. Notemos que en esta función estamos considerando los datos x e y como fijos, y los parámetros $b_0, b_1, \dots, b_p$ y σ^2 como variables. Nuestro siguiente objetivo será encontrar los valores de estos parámetros que maximicen la función de verosimilitud, es decir, que hagan que los datos observados sean lo más consistentes posible con el modelo. Empezaremos por considerar la log-verosimilitud, que es simplemente el logaritmo natural de la función de verosimilitud:

$$\begin{aligned}\ell(b_0, b_1, \dots, b_p, \sigma^2 | x, y) &= \log L(b_0, b_1, \dots, b_p, \sigma^2 | x, y) \\ &= -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - (b_0 + b_1 x_{i1} + \dots + b_p x_{ip}))^2\end{aligned}\quad (3.1)$$

notemos que maximizar la función de verosimilitud es equivalente a maximizar la log-verosimilitud, ya que el logaritmo es una función monótonamente creciente. Por otro lado, para encontrar los valores de

$$b = \begin{bmatrix} b_0 \\ b_1 \\ \vdots \\ b_p \end{bmatrix}$$

que maximicen la log-verosimilitud, nos basta con minimizar la expresión:

$$\sum_{i=1}^n (y_i - (b_0 + b_1 x_{i1} + \dots + b_p x_{ip}))^2$$

Se sigue que podemos utilizar el método de los mínimos cuadrados para encontrar los valores de los parámetros que buscamos:

$$b_{\text{MLE}} = \hat{\beta} = (\Phi^T \Phi)^{-1} \Phi^T y$$

donde

$$\Phi = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix}$$

es la matriz de diseño asociada a nuestros datos. Finalmente, para encontrar el valor de σ^2 que maximice la log-verosimilitud, podemos derivar la expresión (3.1) con respecto a σ^2 y encontrar el valor que hace que la derivada sea cero. Esto nos lleva a la siguiente expresión para el estimador de máxima verosimilitud de σ^2 :

$$\sigma_{\text{MLE}}^2 = \frac{1}{n} \sum_{i=1}^n [y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \dots + \hat{\beta}_p x_{ip})]^2 = \frac{\text{sse}}{n}$$

Desde este punto de vista, hemos obtenido una función que a cada conjunto de datos le asigna su máxima verosimilitud o, más precisamente, su máxima log-verosimilitud bajo el modelo de regresión lineal. Notemos que este valor está dado de manera explícita por:

$$\ell(\hat{\beta}, \sigma_{\text{MLE}}^2 | x, y) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log\left(\frac{\text{sse}}{n}\right) - \frac{n}{2}$$

3. Regresión lineal múltiple

Observación: Notemos que el hecho de que el ajuste por mínimos cuadrados coincida con el ajuste por máxima verosimilitud es una consecuencia de la suposición de que los errores aleatorios ϵ_i siguen una distribución normal. En particular, si los errores no siguieran una distribución normal, entonces el ajuste por máxima verosimilitud podría no coincidir con el ajuste por mínimos cuadrados.

3.2.2. Significancia del modelo y de los parámetros

Nos gustaría ahora poder afirmar que los valores de las variables independientes $X_{01}, X_{02}, \dots, X_{0p}$ tienen un efecto significativo en la variable dependiente Y_0 . En particular, nos gustaría poder afirmar que al menos uno de los parámetros $b_1, b_2, \dots, b_p$ es significativamente distinto de cero. De acuerdo al formalismo de las pruebas de hipótesis, lo que debemos hacer ahora es plantear una hipótesis nula que dice que todos los parámetros son iguales a cero y tratar de reunir una evidencia estadísticamente significativa que nos permita rechazar esta hipótesis. Con estas consideraciones en mente, consideraremos la *suma total de cuadrados* (SST, por sus siglas en inglés) definida como:

$$SST = \sum_{i=1}^n (Y_i - \bar{Y})^2 = \|Y - \bar{Y}\mathbf{1}\|^2$$

donde

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$$

es la media muestral de la variable dependiente y $\mathbf{1}$ es el vector columna de n entradas iguales a uno. La SST se puede interpretar como una variable aleatoria que mide la variabilidad total de los datos asociados a una observación y se puede descomponer como

$$SST = SSR + SSE$$

donde

$$SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \|Y - \hat{Y}\|^2$$

es la suma de los errores al cuadrado que habíamos considerado anteriormente y que corresponde a la variabilidad de los datos que no es explicada por el modelo, y

$$SSR = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 = \|\hat{Y} - \bar{Y}\mathbf{1}\|^2$$

es la *suma de cuadrados de la regresión* y corresponde a la variabilidad de los datos que nuestro modelo explica. Como ya habíamos mencionado anteriormente,

$$\frac{SSE}{\sigma^2} \sim \chi_{n-p-1}^2$$

Por otro lado, bajo la hipótesis nula de que todos los parámetros $b_1, b_2, \dots, b_p$ son iguales a cero, se puede demostrar que

$$\frac{SSR}{\sigma^2} \sim \chi_p^2$$

I. Análisis discriminante lineal

y además, que SSE y SSR son independientes. Con estas consideraciones en mente, podemos definir el estadístico de prueba

$$F = \frac{SSR/p}{SSE/(n-p-1)} \sim F_{p,n-p-1}$$

donde $F_{p,n-p-1}$ es la distribución F de Fisher con p y $n-p-1$ grados de libertad. Notemos que valores grandes de F indican que la variabilidad explicada por el modelo es grande en comparación con la variabilidad no explicada, lo cual constituye evidencia en contra de la hipótesis nula. Por lo tanto, para nuestra prueba de hipótesis, usaremos una regla de una cola por la derecha. En particular, si f es el valor de nuestro estadístico F evaluado en una observación $Y = y$, entonces el p -valor de la prueba es

$$p_F = P_F(F \geq f)$$

Si $p < \alpha$, para algún nivel de significancia α preestablecido, entonces rechazamos la hipótesis nula y concluimos que al menos uno de los parámetros $b_1, b_2, \dots, b_p$ es significativamente diferente de cero. Resumiendo, tenemos el siguiente procedimiento para evaluar la significancia del modelo de regresión lineal:

1. Plantear la hipótesis nula y la hipótesis alternativa:

H_0 : Todos los parámetros son iguales a cero, es decir $b_1 = b_2 = \dots = b_p = 0$

H_1 : Al menos uno de los parámetros $b_1, b_2, \dots, b_p$ es diferente de cero.

2. Calcular el estadístico de prueba

$$F = \frac{SSR/p}{SSE/(n-p-1)}$$

para el vector de datos observados $Y = y$.

3. Calcular el p -valor de la prueba

$$p_F = P_{F_{p,n-p-1}}(F \geq f)$$

donde f es el valor del estadístico F calculado en el paso anterior.

4. Si $p_F < \alpha$, para algún nivel de significancia α preestablecido, entonces rechazamos la hipótesis nula y concluimos que al menos uno de los parámetros $b_1, b_2, \dots, b_p$ es significativamente diferente de cero.

Parte II

Análisis discriminante lineal

Capítulo 4

El modelo discriminante gaussiano

El *análisis discriminante lineal* (LDA, por sus siglas en inglés) es un método de clasificación supervisada que permite separar dos o más clases basándose en las características más relevantes capturadas por un conjunto de datos dado. Este método de clasificación se basa en el *modelo discriminante gaussiano*, que asume que nuestra población se encuentra separada en K clases distintas (también conocidas como grupos o categorías) por una variable categórica G . El modelo también asume que tenemos un vector aleatorio continuo

$$X = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix}$$

que captura las características relevantes de los individuos en nuestra población. Una de las hipótesis más importantes de este modelo es que para cada grupo $G = i$, el vector aleatorio X sigue una distribución normal multivariada con media μ_i y matriz de covarianza Σ , es decir,

$$X|(G = i) \sim \mathcal{N}(\mu_i, \Sigma)$$

Notemos que la matriz de covarianza es la misma para todos los grupos. Esta condición es conocida como *homocedasticidad* y es uno de los supuestos fundamentales del modelo discriminante gaussiano.

4.1. El clasificador bayesiano

Recordemos que una *función de clasificación* es una función g que asigna a cada observación $X = x$ una clase $G = i$, es decir, $g(x) = i$. El objetivo del análisis discriminante lineal es encontrar una función de clasificación que minimice la *tasa de error de clasificación*, la cual está dada por

$$R(g) = E[1_{g(X) \neq G}] = P(g(X) \neq G)$$

donde $1_{g(X) \neq G}$ es una variable indicadora que toma el valor de 1 si la clasificación es incorrecta y 0 en caso contrario, $E[1_{g(X) \neq G}]$ es la esperanza de esta variable aleatoria y $P(g(X) \neq G)$ es la probabilidad de que la clasificación sea incorrecta. La solución al problema de encontrar la función de clasificación óptima está dada por el teorema de Bayes:

Teorema 4.1.1 (Teorema de Bayes para clasificación). *El clasificador que minimiza la tasa de error de clasificación es el clasificador de Bayes $\hat{g}$ que está dado por*

$$\hat{g}(x) = \arg \max_i P(G = i | X = x)$$

donde $P(G = i | X = x)$ es la probabilidad condicional de que la clase sea $G = i$ dado que la observación es $X = x$.

4.2. Las funciones discriminantes lineales

Buscamos ahora una forma más explícita para el clasificador de Bayes bajo el modelo discriminante gaussiano. Empezaremos por introducir las llamadas *probabilidades previas* (también conocidas como *probabilidades a priori* o *priors*) de cada clase, las cuales están dadas por

$$\pi_i = P(G = i)$$

Notemos que este valor es simplemente la probabilidad de que un individuo seleccionado al azar de entre nuestra población pertenezca a la clase $G = i$. También consideraremos las *probabilidades posteriores* (también conocidas como *probabilidades a posteriori* o *posteriors*) de cada clase, las cuales están dadas por

$$P(G = i | X = x)$$

En este caso, este valor representa la probabilidad de que un individuo pertenezca a la clase $G = i$ una vez que hemos observado sus características $X = x$. Para calcular este valor, recordemos que estamos suponiendo que $X | (G = i) \sim \mathcal{N}(\mu_i, \Sigma)$, por lo que la función de densidad condicional de X dado $G = i$ está dada por

$$f_i(X) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (X - \mu_i)^T \Sigma^{-1} (X - \mu_i) \right)$$

Usando la fórmula de Bayes, podemos expresar las probabilidades posteriores en términos de las probabilidades previas y las funciones de densidad condicional:

$$P(G = i | X = x) = \frac{\pi_i f_i(x)}{\sum_j \pi_j f_j(x)}$$

Notemos que el denominador en el lado derecho de esta ecuación es el mismo para todas las clases. En particular, la probabilidad posterior $P(G = i | X = x)$ es un múltiplo positivo de la cantidad $\pi_i f_i(x)$, en símbolos,

$$P(G = i | X = x) \propto \pi_i f_i(x)$$

Se sigue que para encontrar el clasificador de Bayes, podemos concentrarnos en la expresión $\pi_i f_i(x)$. De hecho, como el logaritmo es una función monótonamente creciente, nos basta con concentrarnos en maximizar

$$\begin{aligned} \log(\pi_i f_i(x)) &= \log(\pi_i) + \log(f_i(x)) \\ &= \log(\pi_i) - \frac{p}{2} \log(2\pi) - \frac{1}{2} \log(|\Sigma|) - \frac{1}{2} (x - \mu_i)^T \Sigma^{-1} (x - \mu_i) \\ &= \log(\pi_i) - \frac{p}{2} \log(2\pi) - \frac{1}{2} \log(|\Sigma|) - \frac{1}{2} x^T \Sigma^{-1} x + \mu_i^T \Sigma^{-1} x - \frac{1}{2} \mu_i^T \Sigma^{-1} \mu_i \end{aligned}$$

4. El modelo discriminante gaussiano

Notemos que la expresión

$$-\frac{p}{2} \log(2\pi) - \frac{1}{2} \log(|\Sigma|) - \frac{1}{2} x^T \Sigma^{-1} x$$

aparece en todas nuestras clases. Por lo tanto, si definimos las *funciones discriminantes lineales* como

$$\delta_i(x) = \mu_i^T \Sigma^{-1} x - \frac{1}{2} \mu_i^T \Sigma^{-1} \mu_i + \log(\pi_i)$$

entonces tenemos que las diferencias

$$\Delta_{i,j}(x) = \log(\pi_i f_i(x)) - \log(\pi_j f_j(x)) = \delta_i(x) - \delta_j(x)$$

dependen únicamente de estas funciones. En particular, el clasificador de Bayes se puede reescribir como

$$\hat{g}(x) = \arg \max_i \delta_i(x)$$

4.3. Las variables canónicas

Además de proporcionar un método de clasificación, una de las aplicaciones más importantes del análisis discriminante lineal es la reducción de la dimensionalidad de los datos. De manera más explícita, el análisis discriminante lineal nos permite definir nuevas variables, llamadas *variables canónicas*, que capturan toda la información relevante para separar las distintas clases, pero en un espacio de menor dimensión. Para poder definir estas variables, empecemos por notar que la media total de la población está dada por

$$\mu = E[X] = \sum_i \pi_i \mu_i$$

Definimos ahora la *matriz de dispersión total* como

$$ST = E[(X - \mu)(X - \mu)^T] = \text{Var}[X]$$

Consideraremos también la *matriz de dispersión dentro de los grupos*, la cual está dada por

$$SW = E_G[\text{Var}_X[X|G]] = \sum_i \pi_i \Sigma = \Sigma$$

donde E_G representa la esperanza con respecto a la variable categórica G y $\text{Var}_X[X|G]$ representa la varianza condicional de X dado G . Finalmente, consideraremos la *matriz de dispersión entre los grupos*, la cual está dada por

$$SB = \text{Var}_G[E_X[X|G]] = \sum_i \pi_i (\mu_i - \mu)(\mu_i - \mu)^T$$

donde Var_G representa la varianza con respecto a la variable categórica G y $E_X[X|G]$ representa la esperanza condicional de X dado G . Ya con estas definiciones, podemos escribir la *fórmula de la descomposición de la varianza* que nos dice que

$$ST = SW + SB$$

II. Análisis discriminante lineal

Notemos ahora que si $a = [a_1, a_2, \dots, a_p]$ es una matriz de $1 \times p$, entonces podemos considerar la variable aleatoria $Y = aX$, la cual es una combinación lineal de las variables originales $X_1, X_2, \dots, X_p$. La varianza total de esta nueva variable está dada por

$$\text{Var}[Y] = a(\text{ST})a^T$$

la varianza dentro de los grupos está dada por

$$E_G[\text{Var}_Y[Y|G]] = a(\text{SW})a^T = a\Sigma a^T$$

y la varianza entre los grupos está dada por

$$\text{Var}_G[E_Y[Y|G]] = a(\text{SB})a^T$$

Para construir nuestras variable canónicas, buscamos variables que maximicen la varianza entre los grupos en relación con la varianza dentro de los grupos. En otras palabras, queremos maximizar el *cociente de Rayleigh* definido como

$$J(a) = \frac{a\text{SB}a^T}{a\text{SW}a^T}$$

De manera más precisa, el *criterio de Fisher* nos dice que las variables canónicas deben de satisfacer las siguientes condiciones:

- La primera variable canónica $Y_1 = a_1X$ es aquella que maximiza el cociente $J(a)$, es decir,

$$a_1 = \arg \max_a J(a)$$

- La j -ésima variable canónica $Y_j = a_jX$ es aquella que maximiza el cociente $J(a)$ bajo la restricción de que no esté correlacionada, dentro de los grupos, con las variables canónicas anteriores, es decir,

$$a_j = \arg \max_a J(a) \quad \text{sujeto a} \quad \text{Cov}[Y_i, Y_j|G] = 0 \quad \text{para } i < j$$

Es importante notar que el número máximo de variables canónicas que se pueden obtener es $\min(p, K - 1)$, donde p es el número de características en nuestro vector aleatorio X y K es el número de clases en nuestra población. Esto se debe a que la matriz de dispersión entre los grupos SB tiene rango máximo $r = \min(p, K - 1)$. Finalmente, se puede verificar que las funciones

$$\Delta_{i,j}(x) = \delta_i(x) - \delta_j(x)$$

solo dependen de las primeras r variables canónicas. En particular, esto implica que el clasificador de Bayes también solo depende de estas variables.

Capítulo 5

Ajuste y adecuación del modelo discriminante gaussiano

En el capítulo anterior discutimos el modelo del discriminante gaussiano desde un punto de vista teórico. También describimos como reducir la dimensionalidad de nuestro modelo proyectando los resultados de nuestras observaciones en el espacio LDA que construimos en ese capítulo y, finalmente, mostramos como podemos construir funciones discriminantes lineales que nos permiten clasificar nuestras observaciones basadas solamente en la información contenida en nuestro espacio LDA. En este capítulo estudiaremos como podemos ajustar este modelo a un conjunto de datos dado y verificar la adecuación de este ajuste. Una vez que tenemos un modelo ajustado y verificado, podemos utilizar las técnicas descritas en el capítulo anterior para reducir la dimensionalidad de nuestro conjunto de datos y construir funciones discriminantes lineales que nos permitan clasificar nuevas observaciones.

5.1. Ajuste del modelo discriminante gaussiano

Recordemos que el modelo discriminante gaussiano depende de los siguientes parámetros:

- Los vectores de medias μ_k para cada clase $k = 1, \dots, K$.
- La matriz de covarianza común Σ .
- Los pesos a priori π_k para cada clase $k = 1, \dots, K$.

Nuestro objetivo es estimar estos parámetros a partir de un conjunto de datos etiquetado $\{(x_i, g_i)\}_{i=1}^n$, donde x_i es el vector de características y g_i es la etiqueta de clase correspondiente. Existen dos enfoques principales para ajustar el modelo discriminante gaussiano: el enfoque clásico de LDA que utiliza la estimación de Fisher (FE) para la matriz de varianza común, y el enfoque basado en la estimación por máxima verosimilitud (MLE).

5.1.1. El método de estimación de Fisher (FE)

Para este método de estimación, utilizamos estimadores insesgados para los parámetros del modelo discriminante gaussiano. Las fórmulas para estimar los parámetros son las siguientes:

- Las medias de cada clase se estiman como el promedio de los vectores de características dentro de cada clase:

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i|g_i=k} x_i,$$

donde n_k es el número de observaciones en la clase k , y estamos sumando sobre todos los índices i tales que la etiqueta de clase g_i es igual a k .

- La matriz de covarianza común se estima como la media ponderada de las matrices de covarianza dentro de cada clase:

$$\hat{\Sigma}_{\text{MLE}} = \frac{1}{n - K} \sum_{k=1}^K \sum_{i|g_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^T,$$

- Los pesos a priori se estiman como la proporción de observaciones en cada clase:

$$\hat{\pi}_k = \frac{n_k}{n}$$

Este enfoque es el que se utiliza comúnmente en la literatura estadística y que se implementa en R a través de la función `lda()` del paquete `MASS`.

5.1.2. El método de máxima verosimilitud (MLE)

En este método de estimación, buscamos los parámetros que maximizan la función de verosimilitud del modelo discriminante gaussiano dado el conjunto de datos etiquetado. En este caso, las fórmulas para estimar los parámetros son:

- Las medias de cada clase se estiman de la misma manera que en el método FE:

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i|g_i=k} x_i$$

- La matriz de covarianza común se estima como:

$$\hat{\Sigma}_{\text{MLE}} = \frac{1}{n} \sum_{k=1}^K \sum_{i|g_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^T$$

- Los pesos a priori se estiman como:

$$\hat{\pi}_k = \frac{n_k}{n}$$

Notemos que en este caso, el estimador de la matriz de covarianza común es sesgado, pero consistente. Este enfoque es más común en la literatura de aprendizaje automático y se utiliza en implementaciones como la función `LinearDiscriminantAnalysis` del paquete `scikit-learn` en Python.

5. Ajuste y adecuación del modelo discriminante gaussiano



5.1.3. Comparación de los enfoques FE y MLE

Notemos que la única diferencia entre estos dos enfoques está dada en la forma en la que estimamos la matriz de covarianza común Σ . De manera más precisa, tenemos que:

$$\hat{\Sigma}_{\text{FE}} = \frac{n}{n-K} \hat{\Sigma}_{\text{MLE}}$$

En términos prácticos, esto significa que cuando utilizamos el enfoque FE para calcular las funciones discriminantes, estas funciones le dan más importancia a los valores de los priors en comparación con el enfoque MLE que le da más peso al cálculo de las medias de las clases. Cada uno de estos métodos tiene sus propias ventajas y desventajas, y la elección entre ellos depende de las características específicas del conjunto de datos y del problema en cuestión. A continuación, presentamos una tabla que resume las situaciones en las que cada enfoque puede ser más adecuado:

Contexto	FE LDA	MLE LDA
Tamaño de muestra muy pequeño	✓	
Priors muy desbalanceados	✓	
Confianza alta en los valores de los priors	✓	
Clases balanceadas		✓
Clases bien separadas		✓
Alta dimensionalidad	✓	
Muestras muy grandes	✓	✓

Tabla 5.1: Comparación de los enfoques FE y MLE para el ajuste del modelo discriminante gaussiano.

5.2. Verificación de la adecuación del modelo discriminante gaussiano

Una vez ajustado el modelo discriminante gaussiano a un conjunto de datos, es crucial verificar la adecuación de este ajuste. Esto implica evaluar si las suposiciones del modelo se cumplen y si el modelo es capaz de capturar la estructura subyacente de los datos. A continuación describiremos las pruebas y técnicas más comunes para verificar la adecuación del modelo discriminante gaussiano.

5.2.1. Pruebas de normalidad multivariada

Una de las suposiciones fundamentales del modelo discriminante gaussiano es que las observaciones dentro de cada clase siguen una distribución normal multivariada. Para verificar esta suposición, podemos utilizar pruebas estadísticas como la prueba de Mardia, la prueba de Henze-Zirkler o la prueba de Royston. Estas pruebas evalúan si los datos dentro de cada clase se ajustan a una distribución normal multivariada. Para realizar estas pruebas en R, podemos utilizar el paquete `MVN` que proporciona funciones para llevar a cabo estas pruebas de normalidad multivariada.

Otro método para evaluar la normalidad multivariada es mediante gráficos Q-Q multivariados o gráficos de dispersión de pares de variables dentro de cada clase. Estos gráficos nos permiten visualizar si los datos se ajustan a la distribución normal multivariada esperada.

5.2.2. Pruebas de Homoscedasticidad

Para evaluar si las matrices de covarianza de las diferentes clases son iguales (homoscedasticidad), podemos utilizar la prueba de Box's M. Esta prueba evalúa la hipótesis nula de que todas las matrices de covarianza son iguales contra la alternativa de que al menos una es diferente. En R, podemos utilizar la función `boxM()` del paquete `biotools` para llevar a cabo esta prueba.

Además de la prueba de Box's M, podemos utilizar gráficos de dispersión de las variables dentro de cada clase para visualizar las diferencias en las matrices de covarianza. Si las elipses de dispersión son similares en forma y tamaño, esto sugiere homoscedasticidad.

5.2.3. Evaluación del rendimiento del modelo

Finalmente, es importante evaluar el rendimiento del modelo discriminante gaussiano en términos de su capacidad para clasificar correctamente las observaciones. Podemos utilizar técnicas como la validación cruzada para estimar la tasa de error de clasificación del modelo. Además, podemos construir una matriz de confusión para visualizar el desempeño del modelo en términos de verdaderos positivos, falsos positivos, verdaderos negativos y falsos negativos.

5.3. Modelos alternativos

En caso de que las suposiciones del modelo discriminante gaussiano no se cumplan, podemos considerar modelos alternativos como el modelo discriminante cuadrático (QDA) que permite diferentes matrices de covarianza para cada clase, o modelos basados en técnicas no paramétricas como los árboles de decisión o los métodos de vecinos más cercanos (k-NN). Estos modelos pueden ser más flexibles y adaptarse mejor a conjuntos de datos que no cumplen con las suposiciones del modelo discriminante gaussiano.

Capítulo 6

Método LDA paso a paso para la selección de variables

Como vimos en el capítulo anterior, el análisis discriminante lineal (LDA) es una técnica poderosa para clasificar observaciones en grupos basándose en variables predictoras. Sin embargo, es común que no todas las variables predictoras disponibles satisfagan los supuestos del modelo o contribuyan significativamente a la discriminación entre grupos. En estos casos, disminuir el número de variables puede disminuir el ruido y mejorar la interpretabilidad y el desempeño del modelo, especialmente cuando se presentan problemas de multicolinealidad o de heterocedasticidad. En este capítulo describiremos un enfoque de selección de variables paso a paso (stepwise) para LDA utilizando el paquete `klaR` en R.

6.1. Criterio de selección

En R, el paquete `klaR` ofrece la función `stepclass()` que implementa un procedimiento de selección de variables paso a paso para modelos de clasificación, incluyendo LDA. El criterio utilizado para evaluar la inclusión o exclusión de variables es la tasa de error de clasificación estimada mediante validación cruzada (por defecto, leave-one-out). El objetivo es minimizar esta tasa de error. La función `stepclass()` permite tres estrategias de selección:

1. **Búsqueda hacia adelante** (`direction = "forward"`): comienza con un modelo nulo (sólo el intercepto) y añade variables una por una, seleccionando en cada paso la variable que más reduce la tasa de error.
2. **Búsqueda hacia atrás** (`direction = "backward"`): comienza con un modelo completo (todas las variables) y elimina variables una por una, seleccionando en cada paso la variable cuya eliminación más reduce la tasa de error.
3. **Búsqueda mixta** (`direction = "both"`): combina ambos enfoques, permitiendo añadir o eliminar variables en cada paso según cuál acción reduzca más la tasa de error.

6.2. Flujo recomendado

Para llevar a cabo la selección de variables paso a paso en LDA, usualmente se recomienda seguir el siguiente flujo:

1. **Preparación de datos:** asegúrese de que los datos estén limpios, sin valores faltantes, y que la variable de respuesta sea categórica (factor). Para las variables predictoras, todas ellas deben de ser numéricas. En este paso se puede considerar estandarizar las variables si tienen escalas muy diferentes y eliminar variables redundantes, altamente correlacionadas o con poca variabilidad. Para este proceso de eliminación previa, los diagramas de correlación y las matrices de dispersión son herramientas útiles.
2. **Aplicación de `stepclass()`:** utilice la función `stepclass()` del paquete `klaR` para realizar la selección de variables. Especifique la fórmula del modelo, los datos, el método como "lda" y la dirección de la búsqueda (hacia adelante, hacia atrás o mixta).
3. **Ajuste del modelo final:** una vez obtenida la fórmula final con las variables seleccionadas, ajuste el modelo LDA utilizando la función `lda()` del paquete `MASS`.
4. **Evaluación del modelo:** evalúe el desempeño del modelo final utilizando técnicas de validación cruzada o partición entrenamiento/prueba para estimar la tasa de error fuera de muestra. Compare los resultados con el modelo completo para verificar si la selección de variables ha mejorado el desempeño.
5. **Verificación de supuestos:** revise los supuestos del modelo LDA (normalidad multivariada y homogeneidad de matrices de covarianza) para el modelo final con las variables seleccionadas. Si los supuestos no se cumplen, considere transformaciones de variables o métodos alternativos como QDA o regularización.
6. **Interpretación y reporte:** interprete los resultados del modelo final, incluyendo las variables seleccionadas, los coeficientes discriminantes y las tasas de error. Documente el proceso de selección y justifique las decisiones tomadas durante el análisis.

6.3. Ejemplo ilustrativo

Como ejemplo ilustrativo, consideraremos el conjunto de datos `penguins` del paquete `palmerpenguins`, que contiene medidas morfológicas de tres especies de pingüinos: Adelia, Chinstrap y Gentoo. Nuestro objetivo es clasificar las especies basándonos en las medidas disponibles, seleccionando las variables más relevantes mediante el método paso a paso.

6.3.1. Preparación de datos

Empezaremos por cargar los datos y seleccionar las variables de interés, eliminando observaciones con valores faltantes.

```
library(palmerpenguins)
library(klaR)
library(MASS)
library(dplyr)
```


6. Método LDA paso a paso para la selección de variables



```
library(tidyr)

penguin_data <- penguins %>%
  dplyr::select(
    species,
    bill_length_mm,
    bill_depth_mm,
    flipper_length_mm,
    body_mass_g
  ) %>%
  drop_na() %>%
  mutate(species = droplevels(species)) %>%
  as.data.frame()
```

Nota 6.3.1. El paquete `klaR` no es compatible con tibbles, por lo que es necesario convertir el conjunto de datos a un data frame tradicional usando `as.data.frame()`.

6.3.2. Aplicación de `stepclass()`

Aplicaremos la función `stepclass()` para realizar la selección de variables utilizando las tres estrategias disponibles: hacia adelante, hacia atrás y mixta.

```
# Selección
step_fwd <- stepclass(
  species ~ .,
  data = penguin_data,
  method = "lda",
  direction = "forward"
)

step_bwd <- stepclass(
  species ~ .,
  data = penguin_data,
  method = "lda",
  direction = "backward"
)

step_bth <- stepclass(
  species ~ .,
  data = penguin_data,
  method = "lda",
  direction = "both"
)

# Fórmulas finales
form_fwd <- step_fwd$formula
```

```
form_bwd <- step_bwd$formula
form_bth <- step_bth$formula
```

Las fórmulas finales obtenidas con cada estrategia son:

```
# Convert formula to latex string
latex_formula <- function(f) {
  f_str <- deparse(f)

  # Escape underscores safely
  f_str <- gsub("_", "\\_\\_", f_str)

  # Replace '~' with '\\sim'
  f_str <- gsub("~", "\\sim", f_str)

  # Wrap cleanly in math mode
  latex <- paste0("$", f_str, "$")
  return(latex)
}

formulas_tbl <- tibble::tibble(
  Método = c("Forward", "Backward", "Both"),
  Fórmula = c(
    latex_formula(form_fwd),
    latex_formula(form_bwd),
    latex_formula(form_bth)
  )
)

knitr::kable(
  formulas_tbl,
  format = "latex",
  booktabs = TRUE,
  escape = FALSE
)
```

Método	Fórmula
Forward	$species \sim bill_length_mm + flipper_length_mm$
Backward	$species \sim bill_length_mm + bill_depth_mm + body_mass_g$
Both	$species \sim bill_length_mm + flipper_length_mm$

6.3.3. Ajuste del modelo final

Utilizamos ahora la función `lda()` para ajustar el modelo final con las variables seleccionadas por cada estrategia.

6. Método LDA paso a paso para la selección de variables



```
# Ajuste del modelo final
fit_fwd <- lda(form_fwd, data = penguin_data)
fit_bwd <- lda(form_bwd, data = penguin_data)
fit_bth <- lda(form_bth, data = penguin_data)
```

6.3.4. Evaluación del modelo

Para evaluar el desempeño de los modelos finales, calcularemos la exactitud aparente y las matrices de confusión para cada uno.

```
# Predictions
pred_fwd <- predict(fit_fwd)$class
pred_bwd <- predict(fit_bwd)$class
pred_bth <- predict(fit_bth)$class

# Accuracy
acc_fwd <- mean(pred_fwd == penguin_data$species)
acc_bwd <- mean(pred_bwd == penguin_data$species)
acc_bth <- mean(pred_bth == penguin_data$species)

# Confusion matrices
cm_fwd <- table(Verdadero = penguin_data$species, Predicción = pred_fwd)
cm_fwd <- as.data.frame.matrix(cm_fwd)
cm_fwd <- tibble::rownames_to_column(cm_fwd, var = " ")
names(cm_fwd)[1] <- "Verdadero \\ Predicción"

cm_bwd <- table(Verdadero = penguin_data$species, Predicción = pred_bwd)
cm_bwd <- as.data.frame.matrix(cm_bwd)
cm_bwd <- tibble::rownames_to_column(cm_bwd, var = " ")
names(cm_bwd)[1] <- "Verdadero \\ Predicción"

cm_bth <- table(Verdadero = penguin_data$species, Predicción = pred_bth)
cm_bth <- as.data.frame.matrix(cm_bth)
cm_bth <- tibble::rownames_to_column(cm_bth, var = " ")
names(cm_bth)[1] <- "Verdadero \\ Predicción"
```

Los resultados para las tasas de exactitud son:

```
library(kableExtra)

accuracy_tbl <- tibble::tibble(
  Método = c("Forward", "Backward", "Both"),
  Exactitud = c(acc_fwd, acc_bwd, acc_bth)
)

knitr::kable(
  accuracy_tbl,
```

```
format = "latex",
booktabs = TRUE,
digits = 4,
caption = "Exactitud de los modelos LDA por método de selección"
) %>%
kable_styling(latex_options = "hold_position")
```

Tabla 6.1: Exactitud de los modelos LDA por método de selección

Método	Exactitud
Forward	0.9561
Backward	0.9883
Both	0.9561

La matriz de confusión para el método hacia adelante es:

```
kable(
  cm_fwd,
  format = "latex",
  booktabs = TRUE,
  caption = "Matriz de confusión (Forward)"
) %>%
kable_styling(latex_options = "hold_position")
```

Tabla 6.2: Matriz de confusión (Forward)

Verdadero \ Predicción	Adelie	Chinstrap	Gentoo
Adelie	146	3	2
Chinstrap	6	59	3
Gentoo	0	1	122

La matriz de confusión para el método hacia atrás es:

```
kable(
  cm_bwd,
  format = "latex",
  booktabs = TRUE,
  caption = "Matriz de confusión (Backward)"
) %>%
kable_styling(latex_options = "hold_position")
```

6. Método LDA paso a paso para la selección de variables



Tabla 6.3: Matriz de confusión (Backward)

Verdadero \ Predicción	Adelie	Chinstrap	Gentoo
Adelie	150	1	0
Chinstrap	3	65	0
Gentoo	0	0	123

Finalmente, para el método mixto la matriz de confusión es:

```
kable(
  cm_bth,
  format = "latex",
  booktabs = TRUE,
  caption = "Matriz de confusión (Both)"
) %>%
  kable_styling(latex_options = "hold_position")
```

Tabla 6.4: Matriz de confusión (Both)

Verdadero \ Predicción	Adelie	Chinstrap	Gentoo
Adelie	146	3	2
Chinstrap	6	59	3
Gentoo	0	1	122

6.3.5. Verificación de supuestos

Es importante verificar los supuestos del modelo LDA con las variables seleccionadas. Podemos utilizar pruebas estadísticas y gráficos para evaluar la normalidad multivariada y la homogeneidad de matrices de covarianza. Empezaremos por revisar la normalidad multivariada utilizando el test de Mardia.

```
library(MVN)
# Normalidad multivariada

mardia_fwd <- mvn(
  data = penguin_data %>% dplyr::select(all_of(all.vars(form_fwd)[-1])),
  mvn_test = "mardia"
)

mardia_bwd <- mvn(
  data = penguin_data %>% dplyr::select(all_of(all.vars(form_bwd)[-1])),
  mvn_test = "mardia"
)

mardia_bth <- mvn(
```

```
data = penguin_data %>% dplyr::select(all_of(all.vars(form_bth)[-1])),
mvn_test = "mardia"
)

clean_unicode <- function(df) {
  df[] <- lapply(df, function(x) {
    # Convert to character (safe for factors/logicals)
    x <- as.character(x)
    # Remove all Unicode by transliteration
    x <- iconv(x, from = "UTF-8", to = "ASCII//TRANSLIT")
    # Drop remaining weird symbols
    x <- gsub("[^[:alnum:][:space:].,_\\-]", "", x)
    x
  })
  return(df)
}

clean_mardia_fwd <- clean_unicode(mardia_fwd$multivariate_normality)
clean_mardia_bwd <- clean_unicode(mardia_bwd$multivariate_normality)
clean_mardia_bth <- clean_unicode(mardia_bth$multivariate_normality)
```

Los resultados del test de Mardia para la selección hacia adelante son:

```
knitr::kable(
  clean_mardia_fwd,
  format = "latex",
  booktabs = TRUE,
  caption = "Test de Mardia para normalidad multivariada (Forward)"
) %>%
  kable_styling(latex_options = "hold_position")
```

Tabla 6.5: Test de Mardia para normalidad multivariada (Forward)

Test	Statistic	p.value	Method	MVN
Mardia Skewness	58.996	0.001	asymptotic	Not normal
Mardia Kurtosis	-1.555	0.12	asymptotic	Normal

Para la selección hacia atrás tenemos los siguientes resultados:

```
knitr::kable(
  clean_mardia_bwd,
  format = "latex",
  booktabs = TRUE,
  caption = "Test de Mardia para normalidad multivariada (Backward)"
) %>%
```

6. Método LDA paso a paso para la selección de variables



```
kable_styling(latex_options = "hold_position")
```

Tabla 6.6: Test de Mardia para normalidad multivariada (Backward)

Test	Statistic	p.value	Method	MVN
Mardia Skewness	105.893	0.001	asymptotic	Not normal
Mardia Kurtosis	-3.995	0.001	asymptotic	Not normal

Finalmente, para el método mixto los resultados son:

```
knitr::kable(
  clean_mardia_bth,
  format = "latex",
  booktabs = TRUE,
  caption = "Test de Mardia para normalidad multivariada (Both)"
) %>%
  kable_styling(latex_options = "hold_position")
```

Tabla 6.7: Test de Mardia para normalidad multivariada (Both)

Test	Statistic	p.value	Method	MVN
Mardia Skewness	58.996	0.001	asymptotic	Not normal
Mardia Kurtosis	-1.555	0.12	asymptotic	Normal

Para evaluar la homogeneidad de matrices de covarianza, podemos utilizar la prueba de Box.

```
library(biotools)
# Homogeneidad de matrices de covarianza
box_fwd <- boxM(
  penguin_data %>% dplyr::select(all_of(all.vars(form_fwd)[-1])),
  penguin_data$species
)

box_bwd <- boxM(
  penguin_data %>% dplyr::select(all_of(all.vars(form_bwd)[-1])),
  penguin_data$species
)

box_bth <- boxM(
  penguin_data %>% dplyr::select(all_of(all.vars(form_bth)[-1])),
  penguin_data$species
)

box_results <- tibble::tibble(
  Método = c("Forward", "Backward", "Both"),
```

```

Estadístico = c(box_fwd$statistic, box_bwd$statistic, box_bth$statistic),
`Grados de libertad` = c(
  box_fwd$parameter,
  box_bwd$parameter,
  box_bth$parameter
),
`Valor p` = c(box_fwd$p.value, box_bwd$p.value, box_bth$p.value)
)

knitr::kable(
  box_results,
  format = "latex",
  booktabs = TRUE,
  digits = 4,
  caption = "Prueba de Box para homogeneidad de matrices de covarianza"
) %>%
  kable_styling(latex_options = "hold_position")

```

Tabla 6.8: Prueba de Box para homogeneidad de matrices de covarianza

Método	Estadístico	Grados de libertad	Valor p
Forward	20.3041	6	0.0024
Backward	46.0082	12	0.0000
Both	20.3041	6	0.0024

6.3.6. Interpretación y reporte

En este ejemplo, hemos aplicado el método de selección de variables paso a paso para LDA utilizando el conjunto de datos de pingüinos. Observamos que las diferentes estrategias de selección (hacia adelante, hacia atrás y mixta) pueden conducir a diferentes conjuntos de variables seleccionadas, lo que afecta la exactitud del modelo. Una vez seleccionado el modelo final realizamos una evaluación exhaustiva del desempeño y verificamos los supuestos del modelo. Notemos que las pruebas de normalidad multivariada y homogeneidad de matrices de covarianza nos proporcionan información valiosa sobre la adecuación del modelo LDA con las variables seleccionadas. En nuestro caso, los supuestos no se cumplen completamente, sin embargo, el modelo sigue siendo útil para la clasificación. Finalmente, es crucial documentar todo el proceso de selección y evaluación para asegurar la reproducibilidad y transparencia del análisis.

Parte III

Regresión logística

Capítulo 7

El modelo logístico

En el método de regresión logística, buscamos clasificar las observaciones dadas en dos categorías (usualmente etiquetadas como 0 y 1) basándonos en una o más variables predictoras. A diferencia de la regresión lineal, que predice valores continuos, la regresión logística predice la probabilidad de que una observación pertenezca a una categoría específica. Una vez que hemos determinado estas probabilidades, podemos utilizar el teorema de clasificación de Bayes para asignar cada observación a la categoría más probable. Notemos que el objetivo principal de este método es similar al del Análisis Discriminante Lineal (LDA), pero la regresión logística no asume que las variables predictoras sigan una distribución normal, lo que la hace más flexible en ciertos contextos. En este capítulo estudiaremos las hipótesis estadísticas asociadas con este modelo, y su implementación.

7.1. La función logística y la función logit

Recordemos que la *función logística* está definida como:

$$p = h(z) = \frac{1}{1 + e^{-z}} \quad (7.1)$$

y proporciona una biyección entre los números reales y el intervalo $(0, 1)$. Dado que las probabilidades de un evento siempre se encuentran en este intervalo, la función logística es ideal para modelar probabilidades.

```
# Definición de la función logística
logistic_function <- function(z) {
  1 / (1 + exp(-z))
}

# Ejemplo de uso de la función logística
z_data <- seq(-10, 10, length.out = 100)
p_data <- logistic_function(z_data)

logistic_tbl <- tibble(
  z = z_data,
```

```
p = p_data
)

logistic_plot <- logistic_tbl %>%
  ggplot(aes(x = z, y = p)) +
  geom_line(
    color = c_pal("C blue"),
    linewidth = 1
  ) +
  annotate(
    "text",
    x = -5, y = 0.3,
    label = TeX("$p = \\frac{1}{1 + e^{-z}}$"),
    parse = TRUE,
    size = 4,
    color = c_pal("C blue")
  ) +
  labs(
    title = "La función logística",
    x = TeX("$z$"),
    y = TeX("$p$")
  ) +
  theme_krul()

suppressWarnings(print(logistic_plot))
```

7. El modelo logístico

La función logística




Figura 7.1: Gráfica de la función logística. Notemos que esta función establece una biyección entre los números reales y el intervalo (0, 1), lo cual es ideal para modelar probabilidades.

Notemos que la expresión dada en la ecuación (7.1) es invertible, por lo tanto podemos despejar z en términos de p . Haciendo esto, obtenemos la *función logit*, definida como:

$$z = h^{-1}(p) = \log\left(\frac{p}{1-p}\right) \quad (7.2)$$

La función logit transforma probabilidades (valores entre 0 y 1) en valores reales, lo que es útil para modelar relaciones lineales en el contexto de la regresión logística.

```
# Definición de la función logit
logit_function <- function(p) {
  log(p / (1 - p))
}

# Ejemplo de uso de la función logit
p_data_logit <- seq(0.01, 0.99, length.out = 100)
z_data_logit <- logit_function(p_data_logit)
logit_tbl <- tibble(
  p = p_data_logit,
  z = z_data_logit
)
```

```
logit_plot <- logit_tbl %>%  
  ggplot(aes(x = p, y = z)) +  
  geom_line(  
    color = c_pal("C blue"),  
    linewidth = 1  
  ) +  
  annotate(  
    "text",  
    x = 0.7, y = 2,  
    label = TeX("$z = \\log\\left(\\frac{p}{1-p}\\right)$"),  
    parse = TRUE,  
    size = 4,  
    color = c_pal("C blue")  
  ) +  
  labs(  
    title = "La función logit",  
    x = TeX("$p$"),  
    y = TeX("$z$")  
  ) +  
  theme_krul()  
  
suppressWarnings(print(logit_plot))
```

7. El modelo logístico




Figura 7.2: Gráfica de la función logit. Notemos que esta función transforma probabilidades (valores entre 0 y 1) en valores reales.

7.2. El clasificador logístico

Ahora supongamos que tenemos una variable de respuesta Y_0 que puede tomar solamente dos valores. (Usualmente, estos valores son 0 y 1.) Supongamos además que la relación de esta variable con un vector de variables predictoras

$$X_0 = \begin{bmatrix} X_{01} \\ X_{02} \\ \vdots \\ X_{0p} \end{bmatrix}$$

está dada por la condición

$$Y_0 | (X_0 = x_0) \sim \text{Bernoulli}(p)$$

donde $p = P(Y_0 = 1 | X_0 = x_0)$. En el modelo de regresión logística, suponemos que el logit de p depende linealmente de las variables predictoras, es decir,

$$z = \log\left(\frac{p}{1-p}\right) = b_0 + b_1 x_{01} + b_2 x_{02} + \cdots + b_p x_{0p}$$

para algunos parámetros $b_0, b_1, \dots, b_p$. Usando la función logística, podemos expresar p en términos de las variables predictoras como

$$p = h(z) = \frac{1}{1 + e^{-(b_0 + b_1 x_{01} + b_2 x_{02} + \cdots + b_p x_{0p})}}$$

Notemos que el cociente

$$\frac{p}{1-p} = e^{b_0 + b_1 x_{01} + b_2 x_{02} + \dots + b_p x_{0p}}$$

conocido como la *oportunidad* o *momio* (también conocido como *odds* en inglés) satisface la siguiente condición: por cada unidad que aumente la variable predictora X_{0j} (manteniendo las demás variables constantes), la oportunidad se multiplica por un factor de e^{b_j} . Esta propiedad hace que la regresión logística sea especialmente útil para interpretar el impacto de cada variable predictora en la probabilidad del evento de interés.

Para definir el *clasificador logístico*, fijamos un umbral de probabilidad $\tau \in (0, 1)$. Entonces, asignamos una observación al grupo 1 si la probabilidad estimada p es mayor o igual a τ , y al grupo 0 en caso contrario. En la práctica, un valor comúnmente utilizado para τ es 0.5, lo que significa que asignamos una observación al grupo 1 si la probabilidad estimada de pertenecer a ese grupo es al menos del 50 %. Sin embargo, este umbral puede ajustarse según las necesidades específicas del análisis o las consecuencias de los errores de clasificación. Notemos además que en este caso, la frontera de decisión está dada por

$$\log\left(\frac{\tau}{1-\tau}\right) = 0 = b_0 + b_1 x_{01} + b_2 x_{02} + \dots + b_p x_{0p}$$

Como ejemplo, consideremos el caso en el que tenemos dos variables predictoras ($p = 2$) y los parámetros $b_0 = 0$, $b_1 = 4$ y $b_2 = 4$. En este caso, la frontera de decisión para un umbral $\tau = 0.5$ está dada por la ecuación

$$0 + 4 \cdot x_{01} + 4 \cdot x_{02} = 0$$
$$x_{02} = -x_{01}$$

Para visualizar esta frontera, podemos simular un conjunto de observaciones y clasificar cada punto con el modelo logístico. Usaremos $b_0 = 0$, $b_1 = b_2 = 4$, $\tau = 0.5$ y generaremos 1,000 observaciones para x_1 y x_2 con distribución uniforme en $[-1, 1]$.

```
set.seed(123)

# Parámetros del modelo
b0 <- 0
b1 <- 4
b2 <- 4
tau <- 0.5

# Muestra simulada
sim_tbl <- tibble(
  x1 = runif(1000, min = -1, max = 1),
  x2 = runif(1000, min = -1, max = 1)
) %>%
  mutate(
    z = b0 + b1 * x1 + b2 * x2,
    p_hat = 1 / (1 + exp(-z)),
```


7. El modelo logístico

```

    grupo = if_else(runif(n()) < p_hat, "Grupo 1", "Grupo 0")
  )

# Polígonos para sombrear regiones
region_tbl <- tribble(
  ~region, ~x1, ~x2,
  "Grupo 1", -1.5, 1.5,
  "Grupo 1", 1.5, -1.5,
  "Grupo 1", 1.5, 1.5,
  "Grupo 0", -1.5, -1.5,
  "Grupo 0", 1.5, -1.5,
  "Grupo 0", -1.5, 1.5
)

ggplot() +
  geom_polygon(
    data = region_tbl,
    aes(x = x1, y = x2, fill = region, group = region),
    alpha = 0.5
  ) +
  geom_point(
    data = sim_tbl,
    aes(x = x1, y = x2, color = grupo),
    alpha = 1,
    size = 2
  ) +
  geom_abline(
    intercept = 0,
    slope = -1,
    color = "black",
    linewidth = 1
  ) +
  c_scale_color("C blue", "C green", name = "Grupo") +
  c_scale_fill("C blue", "C green", name = "Región") +
  coord_cartesian(xlim = c(-1, 1), ylim = c(-1, 1)) +
  labs(
    title = "Ejemplo del clasificador logístico",
    x = TeX("$X_{0 \\, , 1}$"),
    y = TeX("$X_{0 \\, , 2}$"),
    fill = "Región",
    color = "Observación"
  ) +
  theme_krul()

```

Ejemplo del clasificador logístico




Figura 7.3: Muestra simulada con el clasificador logístico. Se usan 1,000 observaciones con X_{01} y X_{02} uniformes en $[-1, 1]$. La frontera de decisión $X_{02} = -X_{01}$ aparece en negro; y las regiones correspondientes aparecen sombreadas. Notemos que la clasificación no es perfecta, pero el número de errores decrece de manera exponencial a medida que nos alejamos de la frontera de decisión

Notemos que la clasificación no es perfecta, sin embargo el número de errores decrece de manera exponencial a medida que nos alejamos de la frontera de decisión. Si calculamos la matriz de confusión para este clasificador logístico simulado, obtenemos:

Tabla 7.1: Matriz de confusión para el clasificador logístico simulado.

Verdadero \ Predicción	Grupo 0	Grupo 1
Grupo 0	409	91
Grupo 1	93	407

Capítulo 8

Ajuste y adecuación del modelo de regresión logística

Recordemos que el modelo de regresión logística asume que la variable de respuesta Y_0 está relacionada con el vector de variables explicativas $X_0 = (X_{01}, X_{02}, \dots, X_{0p})$ a través de la siguiente distribución condicional:

$$Y_0 | (X_0 = x_0) \sim \text{Bernoulli}(p_0),$$

donde

$$\text{logit}(p_0) = b_0 + b_1 x_{01} + b_2 x_{02} + \dots + b_p x_{0p},$$

para algunos parámetros $b_0, b_1, \dots, b_p$. En este capítulo estudiaremos el problema de ajustar este modelo a un conjunto de datos y verificar su adecuación. Notemos que una vez que disponemos de un modelo ajustado y verificado, podemos utilizarlo para predecir la probabilidad de que $Y_0 = 1$ dado un valor específico de $X_0 = x_0$. A partir de esta información, podemos utilizar el clasificador de Bayes para asignar una clase a la observación $X_0 = x_0$, lo cual es una de las aplicaciones principales de la regresión logística.

8.1. Ajuste del modelo de regresión logística

Para el ajuste del modelo de regresión logística, utilizamos el método de máxima verosimilitud. Supongamos que disponemos de un conjunto de datos $\{(x_i, y_i)\}_{i=1}^n$, donde $x_i = (x_{i1}, x_{i2}, \dots, x_{ip})$ es el vector de variables explicativas para la i -ésima observación y $y_i \in \{0, 1\}$ es la variable de respuesta correspondiente. La función de verosimilitud para este conjunto de datos es:

$$L(b_0, b_1, \dots, b_p) = \prod_{i=1}^n p_i^{y_i} (1 - p_i)^{1-y_i},$$

donde

$$p_i = \frac{e^{b_0 + b_1 x_{i1} + \dots + b_p x_{ip}}}{1 + e^{b_0 + b_1 x_{i1} + \dots + b_p x_{ip}}}.$$

Para encontrar los estimadores de máxima verosimilitud $\hat{b}_0, \hat{b}_1, \dots, \hat{b}_p$, maximizamos la función de verosimilitud o, de manera equivalente, la log-verosimilitud:

$$\ell(b_0, b_1, \dots, b_p) = \sum_{i=1}^n [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)].$$

Notemos que si tomamos la derivada de la log-verosimilitud con respecto a cada uno de los parámetros y la igualamos a cero, obtenemos un sistema de ecuaciones no lineales que generalmente no tiene una solución analítica cerrada. Por lo tanto, es necesario utilizar métodos numéricos para encontrar los estimadores de máxima verosimilitud. El algoritmo numérico específico depende del paquete computacional que estemos utilizando. En R, por ejemplo, podemos utilizar la función `glm()` con el argumento `family = binomial` para ajustar un modelo de regresión logística utilizando el algoritmo de Newton-Raphson. En Python, podemos utilizar la clase `LogisticRegression` del paquete `scikit-learn`, que implementa el algoritmo de optimización basado en gradiente descendente.

8.2. Adecuación del modelo de regresión logística

Una vez que hemos ajustado el modelo de regresión logística a nuestro conjunto de datos, es importante verificar la adecuación del modelo. Existen varias técnicas para evaluar la adecuación del modelo, entre las cuales destacan las siguientes:

8.2.1. Prueba de razón de verosimilitudes

Una forma común de evaluar la adecuación del modelo es mediante la prueba de razón de verosimilitudes. Esta prueba compara el modelo ajustado con un modelo nulo que no incluye ninguna variable explicativa. La estadística de la prueba se define como:

$$G = -2 [\ell(\text{modelo nulo}) - \ell(\text{modelo ajustado})],$$

donde $\ell(\text{modelo nulo})$ es la log-verosimilitud del modelo nulo y $\ell(\text{modelo ajustado})$ es la log-verosimilitud del modelo ajustado. Bajo la hipótesis nula de que el modelo ajustado no mejora significativamente el ajuste en comparación con el modelo nulo, la estadística G sigue una distribución chi-cuadrado con p grados de libertad, donde p es el número de variables explicativas en el modelo ajustado. Si el valor p asociado a la estadística G es menor que un nivel de significancia predefinido (por ejemplo, 0.05), rechazamos la hipótesis nula y concluimos que el modelo ajustado proporciona un mejor ajuste que el modelo nulo.

8.2.2. Análisis de residuos

Otra técnica para evaluar la adecuación del modelo es el análisis de residuos. En el contexto de la regresión logística, los residuos pueden definirse como la diferencia entre las observaciones reales y las probabilidades predichas por el modelo. Podemos analizar los residuos para detectar patrones sistemáticos que puedan indicar un mal ajuste del modelo. Por ejemplo, podemos graficar los residuos contra las probabilidades predichas o contra cada una de las variables explicativas para identificar posibles tendencias o heterocedasticidad. Además, podemos utilizar pruebas estadísticas, como la prueba de Hosmer-Lemeshow, para evaluar la adecuación del modelo basándonos en los residuos.

8. Ajuste y adecuación del modelo de regresión logística

8.2.3. Curvas ROC y AUC

Las curvas ROC (Receiver Operating Characteristic) y el área bajo la curva (AUC, Area Under the Curve) son herramientas útiles para evaluar el desempeño del modelo de regresión logística en términos de clasificación. La curva ROC representa la relación entre la tasa de verdaderos positivos (sensibilidad) y la tasa de falsos positivos ($1 - \text{especificidad}$) para diferentes umbrales de clasificación. El AUC proporciona una medida cuantitativa del desempeño del modelo, donde un valor de AUC cercano a 1 indica un buen desempeño, mientras que un valor cercano a 0.5 indica un desempeño similar al azar. Podemos utilizar estas métricas para comparar diferentes modelos de regresión logística y seleccionar el que mejor se ajuste a nuestros datos.

